

Projekt - Airline Loyalty Program Promotion and Beyond

Manca Prošek, Tristan Dragan, Patricija Jaklič

06.09.2026

Contents

1	Uvod	3
2	Eksploratorna podatkovna analiza	4
2.1	1. Customer Flight Activity.csv	4
2.2	2. Customer Loyalty History.csv	5
3	Ocena kakovosti podatkov	9
3.1	Magisterska naloga Janeza Bijeca kot osnovi vir	9
3.2	1.način: Na podlagi modela ocenjevanja in terminologije dimenzij kakovosti	9
3.3	Ocenjevanje dimenzij kakovosti	9
3.4	2. način: konceptualni	9
4	Ocena kakovosti podatkov	10
4.1	1.Natančnost podatkov	10
4.2	2.Celovitost	11
4.3	3.Doslednost	12
4.4	4.Pravočasnost	13
4.5	5.Veljavnost	13
4.6	6.Enoličnost	15
5	(Manca) Razumeti dejavnike, ki vplivajo na vključenost v program zvestobe, in analizirati učinkovitost promocijske kampanje	17
5.1	Učinkovitost 2018 promocije	17
5.2	Faktorji, ki vplivajo na engagement	26
6	(Tristan) Identificirajte segmente strank z visoko vrednostjo in predlagajte možne ukrepe za optimizacijo	31
6.1	Osnovno oblikovanje segmentov glede na kvartile in priprava podatkov za analizo skupin . . .	31
6.2	Analiza osnovnih skupin oblikovanih glede na kvantile	34
6.3	Oblikovanje segmentov s pomočjo strojnega učenja in priprava podatkov za analizo skupin . .	39
6.4	Zaključki in priporočila	42
7	(Patricija) Napovedovanje odliva strank oziroma odpovedi ter predlaganje —	44
8	možnih ukrepov za njihovo zadržanje	44
8.1	Definiranje churn	44
8.2	Pregled in analiza spremenljivk	44
8.3	Kategorične spremenljivke	49
8.4	Ugotovitve eksploratorne analize	57
8.5	Napovedovanje odliva strank	58

1 Uvod

V okviru projektne naloge analiziramo podatke programa zvestobe letalske družbe, ki vključujejo dva medsebojno povezana podatkovna vira: podatke o mesečni letalski aktivnosti članov (**Customer Flight Activity**) in podatke o samih članih programa zvestobe (**Customer Loyalty History**), vključno z demografskimi, finančnimi in vedenjskimi značilnostmi.

Cilj naloge je s pomočjo statističnih metod bolje razumeti vedenje strank ter podati priporočila za izboljšanje programa zvestobe. Analizo smo razdelili na naslednje sklope:

- **Eksploratorna podatkovna analiza**, kjer preverimo osnovne značilnosti in porazdelitve spremenljivk v obeh podatkovnih virih.
- **Ocena kakovosti podatkov**, kjer preverimo natančnost, celovitost, doslednost, pravočasnost, veljavnost in enoličnost podatkov ter ustrezno očistimo ugotovljene nepravilnosti (npr. negativne plače, podvojeni zapisi).
- **Razumevanje dejavnikov vključenosti v program in učinkovitost promocijske kampanje 2018**, kjer analiziramo, ali je promocija privabila bolj aktivne oziroma bolj vredne stranke.
- **Segmentacija strank z visoko vrednostjo**, kjer stranke razvrstimo v segmente na podlagi CLV (kvartilna analiza) ter dodatno s pomočjo algoritma k-means glede na vedenjske značilnosti, in predlagamo ukrepe za optimizacijo.
- **Napovedovanje odliva strank (churn)**, kjer raziščemo vzorce prekinitve članstva glede na čas vpisa, demografske in vedenjske značilnosti ter pripravimo podatke za napovedni model, pri čemer posebno pozornost namenimo preprečevanju pojava *data leakage*.


Analiza je bila izvedena s programo R, rezultati posameznih sklopov pa so predstavljeni v nadaljevanju poročila.

2 Eksploratorna podatkovna analiza


2.1 1. Customer Flight Activity.csv

Loyalty Number	Year	Month	Total Flights	Distance	Points Accumulated	Points Redeemed	Dollar Cost Points Redeemed
Min. :100018	Min. :2017	Min. : 1.000	Min. : 0.000	Min. : 0	Min. : 0	Min. : 0.0	Min. : 0.000
1st Qu.:327688	1st Qu.:2017	1st Qu.: 4.000	1st Qu.: 0.000	1st Qu.: 0	1st Qu.: 0	1st Qu.: 0.0	1st Qu.: 0.000
Median :551833	Median :2018	Median : 7.000	Median : 0.000	Median : 0	Median : 0	Median : 0.0	Median : 0.000
Mean :550528	Mean :2018	Mean : 6.514	Mean : 1.295	Mean : 1941	Mean : 2027	Mean : 31.3	Mean : 5.636
3rd Qu.:772194	3rd Qu.:2018	3rd Qu.:10.000	3rd Qu.: 2.000	3rd Qu.: 3018	3rd Qu.: 3039	3rd Qu.: 0.0	3rd Qu.: 0.000
Max. :999986	Max. :2018	Max. :12.000	Max. :28.000	Max. :67284	Max. :100926	Max. :876.0	Max. :158.000

Podatkovni okvir vsebuje mesečno aktivnost članov programa zvestobe (Customer Flight Activity). Vsebuje 392,936 vrstic in 8 stolpcev, pri čemer vsaka vrstica predstavlja en let. Vse spremenljivke so numerične. Vidimo lahko, da so vrednosti v večini smiselne (na primer nimamo negativnega števila vseh letov, ipd.). Podatki so bili zbrani med letoma 2017 in 2018, člani programa zvestobe pa so opravili med 0 in 28 letov. Že iz povzetka lahko razberemo, da so podatki asimetrično porazdeljeni. Razen spremenljivk **Loyalty Number** in **Year**, katerih porazdelitev ni smiselna za analizo ter **Month**, ki je skoraj uniformno porazdeljen. Ni manjkajočih vrednosti.



Vizualizacija potrdi naše sume glede močne (desne) asimetričnosti podatkov. Ta nam lahko v nadaljnjih analizah, kjer predpostavljamo normalnost, povzroča velike težave. Poskusimo jo odpraviti z logaritmiranjem.



Pri večini spremenljivk se z logaritmiranjem precej popravimo asimetričnost, v primeru **Points Redeemed** (vnovčene točke) se celo približamo normalni porazdelitvi, pri **Total Flights** (vsi leti) pa vsaj nekoliko zmanjšamo asimetričnost.


2.2 2. Customer Loyalty History.csv


Table 2: Povzetek podatkov

skim_type	skim_variable	n_missing	complete_rate	numeric.mean	numeric.sd	character.n_unique	character.empty	character.nchar	character.max
character	Country	0	1.00	NA	NA	1	0	6	6
character	Province	0	1.00	NA	NA	11	0	5	20
character	City	0	1.00	NA	NA	29	0	4	14
character	Postal Code	0	1.00	NA	NA	55	0	7	7
character	Gender	0	1.00	NA	NA	2	0	4	6
character	Education	0	1.00	NA	NA	5	0	6	20
character	Marital Status	0	1.00	NA	NA	3	0	6	8
character	Loyalty Card	0	1.00	NA	NA	3	0	4	6
character	Enrollment Type	0	1.00	NA	NA	2	0	8	14
numeric	Loyalty Number	0	1.00	549735.88	258912.13	NA	NA	NA	NA

skim_type	skim_variable	len_missing	complete_n	numeric.mean	numeric.sd	character.n_unique	character.empty	character.nchar	character.max
numeric	Salary	4238	0.75	79245.61	35008.30	NA	NA	NA	NA
numeric	CLV	0	1.00	7988.90	6860.98	NA	NA	NA	NA
numeric	Enrollment Year	0	1.00	2015.25	1.98	NA	NA	NA	NA
numeric	Enrollment Month	0	1.00	6.67	3.40	NA	NA	NA	NA
numeric	Cancellation Year	14670	0.12	2016.50	1.38	NA	NA	NA	NA
numeric	Cancellation Month	14670	0.12	6.96	3.46	NA	NA	NA	NA

Podatkovni okvir vsebuje podatke o članih programa zvestobe (Customer Loyalty History). Vsebuje 16,737 vrstic in 16 stolpcev, pri čemer vsaka vrstica predstavlja posameznega člana iz Kanade. Numeričnih spremenljivk je 7, opisnih pa 9. Tako imamo podatke od izobrazbe in zakonskega stana pa vse do plače. Prav **Salary** (plača) in **CLV** (*Customer lifetime value - total invoice value for all flights ever booked by member* ali skupna vrednost kupca) delujeta asimetrično, dobro bi bilo da preverimo to še vizualno. Spremenljivke z manjkajočimi vrednostmi so: **Salary** (25.32%), **Cancellation Month** (87.65%) in **Cancellation Year** (87.65%). Pri prvi gre za prave manjkajoče vrednosti, pri zadnjih dveh pa vrednost NA pomeni, da član ni zapustil programa zvestobe, kot je to navedeno v pripadajočem gradivu *Airline Loyalty Program Promotion and Beyond_PS 2026*.





Spremenljivka **City** ima 29 kategorij, **Postal Code** pa kar 55, zaradi lažje preglednosti na grafih je dodana še kategorija "Other". **Salary** in **CLV** sta močno (desno) asimetrična zato ju tako kot prejšnje spremenljivke logaritmiramo. Prav tako smo pri spremenljivki **Salary** smo zaznali negativne vrednosti. Pri plači pričakujemo samo pozitivne vrednosti zato bomo v nadaljevanju po principu čiščenja in ocenjevanja kakovosti podatkov obravnavali te vrednosti kot manjkajoče.



Z logaritmiranjem **Salary** in **CLV** smo delno odpravili močno asimetričnost, ki je bila prisotna prej.

3 Ocena kakovosti podatkov

3.1 Magisterska naloga Janeza Bijeca kot osnovi vir

Pri ocenjevanju kakovosti podatkov je pomembno upoštevati namen njihove uporabe, saj so podatki kakovostni takrat, ko so »fit for purpose«, oziroma primerni za namen konkretne analize. Zato je treba način ocenjevanja kakovosti prilagoditi zahtevam in značilnostim posamezne analize. Bijec v magistrskem delu *Statistični kazalniki kakovosti in učinkovitosti oskrbe pacientov s koronarno boleznijo* kakovost podatkov obravnava na dva načina: prvi temelji na modelu ocenjevanja in terminologiji dimenzij kakovosti, prilagojenih elektronskim zdravstvenim podatkom, pri čemer izpostavlja skladnost, celovitost ter prepričljivost oziroma verjetnost podatkov, drugi pa temelji na konceptualnem pristopu. Ta izhodišča so uporabna tudi pri ocenjevanju kakovosti podatkov v naši analizi.

3.2 1. način: Na podlagi modela ocenjevanja in terminologije dimenzij kakovosti

3.2.1 MODEL OCENJEVANJA IN TERMINOLOGIJE DIMENZIJ KAKOVOSTI

- a. SKLADNOST - ali so podatki skladni z definiranimi formati, ustrezajo pričakovani obliki in opisom v metapodatkih (poddimenzije: vrednostna skladnost, relacijska skladnost, računska skladnost)
 - VREDNOSTNA skladnost: spol ima samo dve vrednosti, starost nima negativnih vrednosti,...
 - RELACIJSKA skladnost: omogočanje relacije med tabelami v bazi podatkov
 - RAČUNSKA pravilnost izpeljanih spremenljivk
- b. CELOVITOST - dimenzija kakovosti, ki ocenjuje prisotnost oz. odsotnost (tudi frekvenco podatkov) ne da bi se ozirala na vrednosti, ki jih podatki zavzemajo. Ta dimenzija kakovosti nima poddimenzij.
- c. PREPRIČLJIVOST - VERJETNOST: dimenzija kakovosti, ki osredotoča na same vrednosti, ki jih zavzemajo (imajo podatki) in poskuša odgovoriti na vprašanje, kako vrednosti podatkov opisujejo realno stanje, koliko jim je mogoče zaupati.

Poddimenzije: - UNIKATNA PREPRIČLJIVOST (angl. Uniqueness plausibility) podvajanje podatkov, tam kjer niso smiselni (npr. en identifikator pacienta je povezan z dvema spoloma ali dvema različnima glavnima diagnozama za isto hospitalizacijo) - NEČASOVNA PREPRIČLJIVOST (angl. Atemporal plausibility) Povezana z oceno koliko se vrednosti in porazdelitve vrednosti skladajo glede na neko splošno vedenje ali glede na nek zunanji standard. (npr. telesne višine pacientov se porazdeljuje normalno s povprečjem 170 cm in standardnim odklonom 15cm) - ČASOVNA PREPRIČLJIVOST (angl. Temporal plausibility) Smiselnost in pravilnost spreminjanja ali ohranjanja vrednosti spremenljivk glede na čas (npr. ali je telesna višina pri večini pacientov v adolescenci smiselno naraščala, odraslega pacienta pa ostala nespremenjena)

3.3 Ocenjevanje dimenzij kakovosti

3.3.1 1. vertifikacija (angl. Verification)

Temelji na podatkih kot takih na smiselnosti na ujemanju z omejitvami in strukturo na ekspertnih mnenjih in logičnih povezavah.

3.3.2 2. validacija (angl. Validation)

Temelji na preverjanju podatkov glede na nek zunanji vir, ki lahko predstavlja zlati standard.

3.4 2. način: konceptualni

Avtor poskuša odkriti določene sistemske pomanjklivosti v podatkih. Ideja Weng in Casey -> predpostavka merljivih konceptov v medicini

4 Ocena kakovosti podatkov

Kakovost podatkov bomo preverili na podlagi šestih najbolj uporabljenih dimenzij od petnajstih, ki so navedeni v (6.članku). Odločili smo se za šest dimenzij na podlagi literature in praks.

Glavne dimenzije ocenjevanja kvalitete podatkov, ki jih bomo upoštevali pri naši analizi so:

- 1.Natančnost ali točnost
- 2.Celovitost
- 3.Doslednost
- 4.Pravočasnost
- 5.Veljavnost
- 6.Enoličnost

4.1 1.Natančnost podatkov

Natančnost podatkov pomeni, kako dobro se informacije ujemajo z dejstvi iz resničnega sveta. Natančnost podatkov se osredotoča na pravilnost in zanesljivost podatkov ter zagotavlja, da ti ne vsebujejo napak, ki bi nastale zaradi nepravilnega vnosa ali pomanjkljive obdelave. Primarni cilj zagotavljanja točnosti podatkov je prepoznavanje in odpravljanje napak v podatkovnih vrednostih, kot so napake pri prepisovanju, podvojeni vnosi in napačne vrednosti. Točnost podatkov se dosega z uporabo:

- čiščenja podatkov za prepoznavanje in odpravljanje napak ter neskladnosti v naborih podatkov, kot so odstranjevanje podvojenih zapisov, popravljanje tipkarskih napak in standardizacija podatkov
- preverjanja veljavnosti podatkov s pomočjo vnaprej določenih pravil ali algoritmov za odkrivanje napak, neskladnosti in netočnosti v podatkih med postopkom vnosa ali naknadno
- profiliranja podatkov za prepoznavanje vzorcev, trendov in nepravilnosti v naborih podatkov, ki lahko kažejo na netočnosti ali neskladnosti.

Za naše podatke nimamo zunanjih referenčnih virov s katerim bi lahko naredili neposredno primerjavo podatkov za preverjanje točnosti podatkov, ker nimamo neodvisnega vira točnosti podatkov ne moremo empirično dokazati. Zato bomo v nadaljevanju preverjali logična pravila in potencialne napačne oz ekstremne vrednosti.

Loyalty Number	Year	Month	Total Flights
Min. :100018	Min. :2017	Min. : 1.000	Min. : 0.000
1st Qu.:327688	1st Qu.:2017	1st Qu.: 4.000	1st Qu.: 0.000
Median :551833	Median :2018	Median : 7.000	Median : 0.000
Mean :550528	Mean :2018	Mean : 6.514	Mean : 1.295
3rd Qu.:772194	3rd Qu.:2018	3rd Qu.:10.000	3rd Qu.: 2.000
Max. :999986	Max. :2018	Max. :12.000	Max. :28.000
Distance	Points Accumulated	Points Redeemed	Dollar Cost Points Redeemed
Min. : 0	Min. : 0	Min. : 0.0	Min. : 0.000
1st Qu.: 0	1st Qu.: 0	1st Qu.: 0.0	1st Qu.: 0.000
Median : 0	Median : 0	Median : 0.0	Median : 0.000
Mean : 1941	Mean : 2027	Mean : 31.3	Mean : 5.636
3rd Qu.: 3018	3rd Qu.: 3039	3rd Qu.: 0.0	3rd Qu.: 0.000
Max. :67284	Max. :100926	Max. :876.0	Max. :158.000
Loyalty Number	Country	Province	City
Min. :100018	Length:16737	Length:16737	Length:16737
1st Qu.:326603	Class :character	Class :character	Class :character
Median :550434	Mode :character	Mode :character	Mode :character
Mean :549736			

3rd Qu.:772019
Max. :999986

Postal Code	Gender	Education	Salary
Length:16737	Length:16737	Length:16737	Min. : 15609
Class :character	Class :character	Class :character	1st Qu.: 59265
Mode :character	Mode :character	Mode :character	Median : 73510
			Mean : 79430
			3rd Qu.: 88600
			Max. :407228
			NA's :4258

Marital Status	Loyalty Card	CLV	Enrollment Type
Length:16737	Length:16737	Min. : 1898	Length:16737
Class :character	Class :character	1st Qu.: 3981	Class :character
Mode :character	Mode :character	Median : 5780	Mode :character
		Mean : 7989	
		3rd Qu.: 8941	
		Max. :83325	

Enrollment Year	Enrollment Month	Cancellation Year	Cancellation Month
Min. :2012	Min. : 1.000	Min. :2013	Min. : 1.000
1st Qu.:2014	1st Qu.: 4.000	1st Qu.:2016	1st Qu.: 4.000
Median :2015	Median : 7.000	Median :2017	Median : 7.000
Mean :2015	Mean : 6.669	Mean :2017	Mean : 6.963
3rd Qu.:2017	3rd Qu.:10.000	3rd Qu.:2018	3rd Qu.:10.000
Max. :2018	Max. :12.000	Max. :2018	Max. :12.000
		NA's :14670	NA's :14670

4.2 2.Celovitost

Podatki so celoviti, če so prisotni vsi potrebni podatki ali so določene vrednosti manjkajoče. Celovitost ne pomeni le odsotnosti praznih polj, temveč tudi, ali zbrani podatki zadostno pokrivajo vse pomembne vidike analiziranega pojava.

Loyalty Number	Year
0	0
Month	Total Flights
0	0
Distance	Points Accumulated
0	0
Points Redeemed Dollar Cost	Points Redeemed
0	0

Cancellation Year	Cancellation Month	Salary	Loyalty Number
0.8765012	0.8765012	0.2544064	0.0000000
Country	Province	City	Postal Code
0.0000000	0.0000000	0.0000000	0.0000000
Gender	Education	Marital Status	Loyalty Card
0.0000000	0.0000000	0.0000000	0.0000000
CLV	Enrollment Type	Enrollment Year	Enrollment Month
0.0000000	0.0000000	0.0000000	0.0000000

V izpisanih tabelah lahko vidimo, da podatki o letih nimajo manjkajočih vrednosti, prav tako bi iz podakih podatkov rekli, da so podane vse potrebne vrednosti.

V tabeli podatkov o članih programa pa opazimo, da imamo manjkajoče vrednosti pri spremenljivki 'Salary'

in pa seveda pri spremenljivkama 'Cancellation Year' in 'Cancellation Month', ki pa niso manjkajoči podatki, saj so to še aktualni člani in podatka enostavno ni. Tudi pri tem naboru podatkov bi za dane stolpce rekli, da so podatki dovolj obsežni in nam podajajo dovolj informacij za celovitost.

Vrnimo se sedaj k spremenljivki o plačah, kjer nam manjka 25% vrednosti. Trend manjkajočnosti si tu želimo bolj natančno pogledati, če uspemo najti kakšen vzorec.

```
# A tibble: 2 x 2
  Gender      n
  <chr>  <int>
1 Female  2094
2 Male    2164

# A tibble: 3 x 2
  `Loyalty Card`      n
  <chr>              <int>
1 Aurora              797
2 Nova               1341
3 Star               2120

# A tibble: 3 x 2
  `Marital Status`      n
  <chr>              <int>
1 Divorced            378
2 Married           1451
3 Single            2429

# A tibble: 3 x 2
  Education      n
  <chr>          <int>
1 Bachelor        19
2 College       4238
3 High School or Below    1

# A tibble: 5 x 2
  Education      n
  <chr>          <int>
1 Bachelor    10475
2 College     4238
3 Doctor       734
4 High School or Below  782
5 Master       508
```

Našli smo vzorec manjkajočnosti, in sicer podatek o plači je manjkajoč pri vseh, ki imajo nivo izobrazbe enak "College".

4.3 3.Doslednost

Doslednost podatkov pa predstavlja njihovo ujemanje med različnimi viri, sistemi ali časovnimi obdobji. Podatki so dosledni, kadar ni protislovij in kadar so medsebojno logično skladni.

[1] 0

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.000	0.000	0.000	1.295	2.000	28.000

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0	0	0	1941	3018	67284

```

# A tibble: 0 x 8
# i 8 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>,
#   Total Flights <dbl>, Distance <dbl>, Points Accumulated <dbl>,
#   Points Redeemed <dbl>, Dollar Cost Points Redeemed <dbl>

# A tibble: 0 x 8
# i 8 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>,
#   Total Flights <dbl>, Distance <dbl>, Points Accumulated <dbl>,
#   Points Redeemed <dbl>, Dollar Cost Points Redeemed <dbl>

  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
15609  59265   73510   79430   88600  407228   4258

# A tibble: 0 x 16
# i 16 variables: Loyalty Number <dbl>, Country <chr>, Province <chr>,
#   City <chr>, Postal Code <chr>, Gender <chr>, Education <chr>, Salary <dbl>,
#   Marital Status <chr>, Loyalty Card <chr>, CLV <dbl>, Enrollment Type <chr>,
#   Enrollment Year <dbl>, Enrollment Month <dbl>, Cancellation Year <dbl>,
#   Cancellation Month <dbl>

```

Pogledali smo še, če imajo vsi podatki o letih veljavno številko kartice zvestove v podatkih o kartičarjih in pa če obstajajo, kakšne nesmiselne vrednosti. Opazili smo negativne plače, ki jih bomo obravnavali pod točko 5, razen tega pa podatki delujejo dosledni.

4.4 4.Pravočasnost


Pravočasnost nam pove, ali so podatki na voljo dovolj hitro glede na potrebe uporabe in ali odražajo trenutno stanje. Pri analizi odtoka strank to pomeni, da podatki o vedenju strank ne smejo biti zastareli, saj se preference in vedenje hitro spreminjajo.

Ker analiziramo bazo starih podatkov in imamo pomanjkljive informacije o pridobitvi podatkov in prav tako o pridobivanju, bomo to točko spustili. Omenili smo jo, ker je izredno pomembna pri vseh analizah kakovosti podatkov in je ne smemo pozabiti. Za potrebe naše naloge bomo rekli, da so podatki pravočasni in da dobro odražajo trenutno stanje.

4.5 5.Veljavnost

Kot je bilo že ugotovljeno zgoraj smo opazili negativne vrednosti pri spremenljivki 'Salary', kar ni pričakovano. Te vrednosti smo zaznali kot neveljavne. V nadaljevanju bomo preverili ali obstaja kakšen vzorec negativnih vrednosti in se na podlagi podrobnejšega pregleda podatkov odločili kaj bomo z njimi naredili.

Porazdelitev spremenljivke Salary



```
# A tibble: 1 x 3
  n min_salary max_salary
<int>      <dbl>      <dbl>
1     0      Inf      -Inf

[1] 0

# A tibble: 0 x 2
# i 2 variables: Gender <chr>, n <int>

# A tibble: 0 x 2
# i 2 variables: Education <chr>, n <int>

# A tibble: 0 x 2
# i 2 variables: Loyalty Card <chr>, n <int>

Loyalty Number  Country      Province      City
Min.   : NA    Length:0      Length:0      Length:0
1st Qu.: NA    Class :character Class :character Class :character
Median : NA    Mode  :character Mode  :character Mode  :character
Mean   :NaN
3rd Qu.: NA
Max.   : NA

Postal Code      Gender      Education      Salary
Length:0        Length:0      Length:0      Min.   : NA
Class :character Class :character Class :character 1st Qu.: NA
Mode  :character Mode  :character Mode  :character Median : NA
                                          Mean   :NaN
                                          3rd Qu.: NA
```

```

Max. : NA
Marital Status      Loyalty Card      CLV      Enrollment Type
Length:0            Length:0            Min. : NA      Length:0
Class :character    Class :character  1st Qu.: NA    Class :character
Mode :character     Mode :character  Median : NA    Mode :character
                    Mean :NaN
                    3rd Qu.: NA
                    Max. : NA
Enrollment Year Enrollment Month Cancellation Year Cancellation Month
Min. : NA      Min. : NA      Min. : NA      Min. : NA
1st Qu.: NA    1st Qu.: NA    1st Qu.: NA    1st Qu.: NA
Median : NA    Median : NA    Median : NA    Median : NA
Mean :NaN      Mean :NaN      Mean :NaN      Mean :NaN
3rd Qu.: NA    3rd Qu.: NA    3rd Qu.: NA    3rd Qu.: NA
Max. : NA      Max. : NA      Max. : NA      Max. : NA

```

4.6 6.Enoličnost

Enoličnost podatkov pomeni odsotnost podvojenih zapisov. To pomeni, da mora biti vsaka entiteta v podatkovni bazi zastopana samo enkrat. Enoličnost je pomembna za pravilno združevanje in preprečevanje dvojnega štetja pri analizah.

```

# A tibble: 0 x 2
# i 2 variables: Loyalty Number <dbl>, n <int>

# A tibble: 3,847 x 4
  `Loyalty Number` Year Month    n
      <dbl> <dbl> <dbl> <int>
1      101902  2017     1     2
2      101902  2017     2     2
3      101902  2017     3     2
4      101902  2017     4     2
5      101902  2017     5     2
6      101902  2017     6     2
7      101902  2017     7     2
8      101902  2017     8     2
9      101902  2017     9     2
10     101902  2017    10     2
# i 3,837 more rows

```

V zgornjem izpisu vidimo, da dvojnih vnosov o strankah ni, je pa kar veliko dvojnih vnosov v tabeli z leti. Če pogledamo dvojne vnose bolj natančno, opazimo, da imamo dve vrsti. Imamo dvojne vnose, ki so popolni dvojniki in imamo vnose, kjer so številka kartice zvestobe, leto in mesec enaki, ostali podatki pa so si med seboj različni. To sta dva problema, ki ju bomo obravnavali ločeno.

```
[1] 1904
```

```
[1] 1943
```

```

# A tibble: 10 x 8
  `Loyalty Number` Year Month `Total Flights` Distance `Points Accumulated`
      <dbl> <dbl> <dbl>      <dbl>      <dbl>      <dbl>
1      101902  2017     4          1        667        667
2      101902  2017     4          1       2499       2499
3      101902  2017     5          3       7263       7263
4      101902  2017     5          2       3762       3762
5      101902  2017     6          3       4971       4971

```

6	101902	2017	6	3	5763	5763
7	101902	2017	8	5	3825	3825
8	101902	2017	8	4	8952	8952
9	101902	2017	9	2	3734	3734
10	101902	2017	9	1	2187	2187

```
# i 2 more variables: `Points Redeemed` <dbl>,
# `Dollar Cost Points Redeemed` <dbl>
```

- Obravnava popolnih dvojniki - literatura

V viru 9 (Rahm in Do, 2000, Data Cleaning: Problems and Current Approaches) avtorja navajata, da odprava dvojniki poteka v dveh korakih. Najprej identifikacija, ki smo jo že naredili, nato pa združitev oziroma odstranitev podvojenih zapisov. Ker imamo v našem primeru opravka s popolnimi dvojniki, kjer se vse vrednosti atributov ujemajo, med njimi ni nobenih protislovij ali manjkajočih informacij, ki bi jih bilo treba uskladiti. Zato lahko brez izgube podatkovne vsebine eno od kopij enostavno odstranimo, s čimer preprečimo dvojno štetje strank v nadaljnjih analizah, hkrati pa ohranimo celovitost in konsistentnost podatkovne baze.

- Obravnava nepopolnih dvojniki - literatura

V viru 7 (Bleiholder & Naumann, 2008, ACM Computing Surveys, "Data Fusion"), ki govori o usklajevanju nasprotujočih si vrednosti, obstaja uveljavljena klasifikacija strategij, ki ločuje tri pristope:

- Conflict-resolving (razreševanje konflikta), kjer si izbereš eno vrednost na podlagi nekega kriterija: zanesljivosti vira, časovne novosti zapisa, večinskega glasovanja med več viri, ali domenskega znanja.
- Conflict-avoiding (izogibanje), kjer uporabiš pravilo (npr. vedno vzemi maksimum, minimum, povprečje).
- Conflict-ignoring (nerazreševanje), kjer se konflikta sploh ne poskuša razrešiti, temveč se pusti nerazrešen ali označi kot neznan.

Prvi dve zgornji strategiji razreševanja potrebujeata vsaj neko dodatno informacijo, na podlagi katere bi se odločili, katera vrednost je pravilnejša. To bi bil lahko podatek o viru, časovni žig vnosa podatkov, nek drug dodatek vir in podobno. Ker pa mi poleg podatkov nimamo drugega in so si nekatere naše vrednosti nasprotujoče (število letov in prepotovana razdalja v teh primerih nista pozitivno povezana), bi bila izbira ene od privih dveh rešitev zgolj ugibanje. To tudi Rahm & Do (2000) in Restat et al. (2025) izpostavita kot problem, da brez dodatnih pravil ali človeške presoje se kontradiktornega zapisa ne da zanesljivo razrešiti.

Zato je tudi v literaturi v takšnih primerih priznana pot nerazreševanja, saj namesto, da se izmislimo, katera vrednost je prava, oba zapisa označimo kot manjkajoč podatek. S tem ne vnašamo umetne pristranskosti v podatke, ohranjamo transparentnost in če bi bilo takih podatkov veliko, jih lahko obravnavamo kot manjkajoče vrednosti. Je pa pomembno dodati, da je delež nepopolnih dvojniki majhen in ne vpliva na rezultate naših nadaljnjih analiz.

Kljub temu podatke sčistimo kot smo se s pomočjo literature odločili.

```
Vrstic prej: 392936
```

```
Odstranjenih (nepopolni dvojniki - vse vrstice skupine): 3894
```

```
Odstranjenih (odvečne kopije popolnih dvojniki): 1920
```

```
Vrstic po čiščenju: 387122
```

```
# A tibble: 0 x 4
```

```
# i 4 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>, n <int>
```


5 (Manca) Razumeti dejavnike, ki vplivajo na vključenost v program zvestobe, in analizirati učinkovitost promocijske kampanje

1. Dejavniki angažiranja: večdimenzionalne koristi in heterogenost uporabnikov

Razumevanje dejavnikov, ki vplivajo na vključenost in delovanje strank v programih zvestobe, zahteva celovit pogled na zaznane koristi, ki jih programi ponujajo. Mimouni-Chaabane in Volle (2009) poudarjajo pet vrst koristi, in sicer denarno, raziskovalno, zabavno, prepoznavno in socialno. Pri tem je pomembno omeniti, da denarni prihranki veljajo za najpomembnejši motivator, vendar se ne sme spregledati hedonskih in simbolnih koristi, ki za dolgoročno vključenost postanejo vse pomembnejše. Dorotic, Bijmolt in Verhoef (2011) to dopolnjujejo z ugotovitvijo, da se pomen koristi po vključitvi v program spreminja, saj so utilitarne koristi ključne za privabljanje novih članov, hedonske in simbolne koristi pa so pomembnejše za zadrževanje članov skozi čas. Poleg tega Liu (2007) dokazuje, da se odziv na program zvestobe bistveno razlikuje glede na začetno raven porabe strank. Težki kupci se sicer najbolj poslužujejo nagrad, vendar ne spreminjajo svojega vedenja, medtem ko lahki in zmerni kupci postopoma povečujejo pogostost nakupov in zvestobo. Ta heterogenost je ključnega pomena pri načrtovanju promocijskih kampanj, saj enaka spodbuda ne bo enako učinkovita pri vseh strankah. Verhoef (2003) dodaja, da čustvena zavezanost deluje kot posrednik med zaznanimi koristmi in dejanskim vedenjem, in s tem svetuje, da morajo kampanije graditi tudi čustveno povezanost s podjetjem, ne le ciljati na kratkoročne ekonomske spodbude.

2. Psihološki mehanizmi in vpliv dizajna programa na učinkovitost kampanj

Učinkovitost promocijskih kampanj je odvisna od razumevanja treh sočasno delujočih psiholoških mehanizmov, ki poganjajo vedenje potrošnikov. Henderson, Beck in Palmatier (2011) identificirajo tri ključne mehanizme (status, navado in odnos), ki delujejo sočasno in medsebojno vplivajo drug na drugega. Promocijska kampanja, ki temelji izključno na enem mehanizmu (npr. statusu preko ekskluzivnih nagrad), lahko spodbudi angažiranje pri enem segmentu, hkrati pa povzroči negativne učinke pri drugih (npr. občutek nepravilnosti ali zmanjšanje notranje motivacije). Dorotic, Bijmolt in Verhoef (2011) dodajajo mehanizma pritiska točk in nagrajenega vedenja kot odgovorna za kratkoročne in dolgoročne učinke programov. Kratkoročni učinki so značilni predvsem za časovno omejene promocije, medtem ko dolgoročni učinki zahtevajo premišljeno oblikovanje programa, ki nagraduje rednost in zvestobo skozi daljše obdobje. Liu (2007) potrjuje, da se največja sprememba v vedenju zgodi v prvih treh mesecih po vključitvi v program, kar nakazuje, da so začetne promocijske kampanje ključnega pomena, saj morajo stranke v tem obdobju zaznati dovolj vrednosti, da razvijejo nove nakupne navade.

3. Ključni dejavniki za oceno učinkovitosti promocijskih kampanj

Pri analizi učinkovitosti promocijskih kampanj je nujno upoštevati več ključnih dejavnikov, ki lahko bistveno vplivajo na interpretacijo rezultatov. Prvič, samoizbira je kritičen dejavnik, saj so stranke, ki se vključijo v program, pogosto že bolj zveste, zato primerjava med člani in nečlani programa vodi v precenjevanje učinkovitosti (Dorotic, Bijmolt & Verhoef, 2011; Verhoef, 2003). Za zanesljivo oceno učinkovitosti promocijske kampanje je zato nujna longitudinalna analiza iste skupine strank pred in po izvedbi kampanje, kot to priporočata tako Liu (2007) kot Verhoef (2003). Drugič, konkurenčni programi in nasičenost trga zmanjšujejo učinkovitost posameznega programa, saj se v okolju, kjer imajo vsi ponudniki podobne programe zvestobe, diferenciacija hitro izgubi. Promocijske kampanje morajo tako iskati edinstvene vrednostne predloge, ki jih konkurenca ne more enostavno posnemati (Mimouni-Chaabane & Volle, 2009; Dorotic, Bijmolt & Verhoef, 2011). Tretjič, časovni okvir ocenjevanja je ključen, saj kratkoročni učinki promocijskih kampanj ne odražajo nujno dolgoročne učinkovitosti. Liu (2007) dokazuje, da se dolgoročni učinki pri lahkih in zmernih kupcih pokažejo šele po več mesecih, kar pomeni, da mora ocena učinkovitosti kampanje vključevati dovolj dolgo obdobje spremljanja.

5.1 Učinkovitost 2018 promocije

Wilcoxon rank sum test with continuity correction

Table 3: Povprečja

Metrika	2018 Promotion	Standard
n	971.00	15766.00
povp_flights	45.85	28.98
povp_distance	68826.98	43437.28
povp_CLV	8046.51	7985.35
povp_accumulated	103240.48	43437.28
povp_redeemed	383.00	744.79
povp_redemption_rate	0.00	0.02
povp_dollar_redeemed	68.96	134.08
churn_rate	0.12	0.12

data: CLV by Enrollment Type
W = 7683302, p-value = 0.8432
alternative hypothesis: true location shift is not equal to 0

Pearson's Chi-squared test

data: table(df\$`Enrollment Type`, df\$`Loyalty Card`)
X-squared = 0.68438, df = 2, p-value = 0.7102

Pearson's Chi-squared test

data: table(df\$`Enrollment Type`, df\$Province)
X-squared = 35.902, df = 10, p-value = 0.00008751

Pearson's Chi-squared test

data: table(df\$`Enrollment Type`, df\$Salary)
X-squared = 8308.5, df = 5869, p-value < 0.00000000000000022

Pearson's Chi-squared test with Yates' continuity correction

data: table(df\$`Enrollment Type`, df\$Gender)
X-squared = 0.13677, df = 1, p-value = 0.7115

Pearson's Chi-squared test

data: table(df\$`Enrollment Type`, df\$`Marital Status`)
X-squared = 0.68296, df = 2, p-value = 0.7107

Pearson's Chi-squared test

data: table(df\$`Enrollment Type`, df\$Education)
X-squared = 8.5422, df = 4, p-value = 0.07362

Welch Two Sample t-test

```

data: total_flights_sum by Enrollment Type
t = 24.987, df = 1042.6, p-value < 0.00000000000000022
alternative hypothesis: true difference in means between group 2018 Promotion and group Standard is not
95 percent confidence interval:
 15.54703 18.19698
sample estimates:
mean in group 2018 Promotion      mean in group Standard
          45.84758                28.97558

```

Wilcoxon rank sum test with continuity correction

```

data: points_accumulated by Enrollment Type
W = 13176777, p-value < 0.00000000000000022
alternative hypothesis: true location shift is not equal to 0

```

Wilcoxon rank sum test with continuity correction

```

data: points_redeemed by Enrollment Type
W = 5434755, p-value < 0.00000000000000022
alternative hypothesis: true location shift is not equal to 0



```



Wilcoxon rank sum test with continuity correction

```


data: redemption_rate by Enrollment Type
W = 4248464, p-value < 0.00000000000000022
alternative hypothesis: true location shift is not equal to 0

```






Zakonski stan glede na tip vpisa



Izobrazba glede na tip vpisa



Opisna statistika v tabeli nam pokaže, da je promocija iz leta 2018 privabila 971 novih članov, ki so v

letih 2017 in 2018 (kar imamo podatke) leteli v povprečju kar 45-krat, medtem ko so normalne stranke programa povprečno letele le 29-krat. Zelo hitro je jasno, da je promocija pripeljala stranke, ki so bolj pogosti uporabniki letalskih družb, kot standardno pridobljeni kartičarji. Omeniti je potrebno, da smo spodnje teste najprej naredili na povprečju vseh podatkov, ki smo jih imeli, čeprav smo za nekatere promocijske člane imeli vnose že kakšen mesec pred priključitvijo programu. Ker je bil to zgolj en ali dva meseca, te podatki na slednje ugotovitve statistično značilno niso vplivali, morda so vrednosti le podcenili, smo pa kasneje pri analizi upoštevali tudi to informacijo.

Testi za primerjavo skupin po načinu vpisa (standardno ali promocijsko) kažejo naslednje rezultate. Stranke, ki so se vključile preko promocije, so v opazovanem obdobju v povprečju opravile skoraj 17 letov več od standardno vpisanih strank. Ta razlika je statistično visoko značilna, saj Welchov t-test vrne rezultate $t = 24.987$ in $p\text{-value} < 2.2e-16$. Povprečni vrednosti vidni v tabeli pa sta za promocijsko skupino 45.8 in za standardno skupino 28.9.

Testi za primerjavo zbiranja in koriščenja točk glede na vrsto vpisa so visoko značilni med skupinama, vendar pa nam samo ta rezultat ne pove, katera skupina je bistveno boljša. Zato se obrnemo na tabelo s primerjavo, kjer opazimo, da medtem ko promocijski člani zberejo bistveno več točk zvestobe, so standardno včlanjeni člani tisti, ki jih več porabijo. Redemption rate je v povprečju pri standardnih članih 1.7%, medtem ko je pri promocijskih le 0.4%.

Promocija je torej privabila stranke, ki letijo veliko, vendar se ne ozirajo na koriščenje finančnih ugodnosti, ki jih program nudi. Potrebna bi bila nadaljna obravnava po plačilnem razredu in izobrazbi, vendar sklep je, da stranke, ki veliko letijo nimajo finančnih zadržkov in jih tako točke zvestobe niso pomemben del programa. Morda so jim bolj važne druge ugodnosti, ki jih program zvestobe nudi, vendar teh podatkov pa žal nimamo.

Po primerjavi povprečnih vrednosti opazimo, da je ri skupini normalno vključenih članov povprečno prepotovana razdalja enaka 43.437 in povprečno število zbranih točk je enako 43.437. Torej popolnoma enako. Pri skupini 2018 promocije, pa je povprečno prepotovana razdalja enaka 68.827, število zbranih točk pa je enako 103.240, kar je natanko 1,5-kratnik razdalje. To ni naključje, saj nakazuje, da dobijo promocijske stranke 1.5 točke na prevoženi km, medtem ko standardne zgolj 1 točko na km.

Table 4: Točke na km

Enrollment Type	tocke_na_km
2018 Promotion	1.5
Standard	1.0

Ta ugotovitev deloma pojasni, zakaj promocijski člani nabirajo toliko več točk kot navadni. Promocijska kampanija ni bila le normalno oglaševanje programa, vendar je vključevalo dodatne ugodnosti za člane, ki se pridružijo v določenem obdobju.

Po drugi strani pa se CLV med skupinama praktično ne razlikuje, saj so rezultati Wilxonovega testa $W = 7683302$ in $p\text{-vrednost} = 0.8432$. Promocija torej ni pritegnila strank z višjo dolgoročno vrednostjo, temveč zgolj bolj aktivne letalce. Tu je pomembno omeniti, da naši podatki obsegajo le dve leti. Torej v teh dveh letih promocija ni pritegnila strank z višjo CLV, bi bilo pa zanimivo videti daljše obdobje in rezultate le teh.


Spomnimo se na mehanizme, ki jih omenjajo Henderson, Beck & Palmatier (2011), ki pravijo, da promocija z bonus stopnjo nabiranja točk cilja predvsem na mehanizma statusa in navade (hitrejše kopičenje nagrad), ne pa nujno na mehanizem odnosa (čustvena zavezanost), o katerem govori Verhoef (2003). To je zagotovo eden od razlogov, zakaj promocija poveča aktivnost, ne pa tudi dolgoročne vrednosti (CLV) strank.

Tip kartice zvestobe (Star/Nova/Aurora) ni statistično povezan z vrsto vpisa, saj je Chi test vrnil rezultate $X\text{-squared} = 0.68438$ in $p\text{-value} = 0.7102$. Promocija torej ni bila bolj privlačna za določen segment kartic.


Pomembna opomba je, da ker gre bolj za opazovalne podatke, višja aktivnost promocijske skupine ne pomeni nujno, da je promocija vzročno povečala angažiranost. Enako verjeten scenarij je samoselekcija, pred katero opozarjajo Dorotic, Bijmolt & Verhoef (2011), in sicer da so se bolj pogosti letalci raje odločili za vključitev

preko promocije. Za bolj zanesljiv vzročni zaključek bi bilo treba narediti longitudinalno primerjavo iste skupine pred in po vključitvi.


Aktivnost letenja pred in po vpisu v 2018 Promotion



Standarda skupina: koledarska aktivnost letenja



Standarda skupina: koledarska aktivnost letenja



Standarda skupina kaže jasen sezonski vzorec, saj vidimo, da so bili vrhovi števila letov poleti, specifično meseca julija. Najnižje številke letov pa so bile meseca januarja in aprila. To je bil jasen vzorec v obeh letih. S tem potrjujemo, da je splošna sezonskost realna in jo je treba ločiti od morebitnega učinka promocije, ki bi ga lahko interpretirali iz prvih dveh grafov.

5.1.0.1 Diff in diffanaliza Do so rezultati nakazali učinkovitost promocije, vendar so bili tako v testih opisne statistike kot v zgornjih grafih prisotni problemi, ki nam ne zagotovijo učinkovitosti promocije. Zato bomo sedaj naredili diff-in-diff analizo, ki rešuje oba primera z eno idejo: namesto primerjave ravni aktivnosti med skupinama, primerjamo, kako se je aktivnost spremenila znotraj vsake skupine med dvema obdobjema in šele te spremembe primerjamo med seboj.

Ker se je promocija začela šele leta 2018, smo se odločili, da si želimo primerjati spremembo med skupinama po kvartalnih.

Call:

```
lm(formula = `Total Flights` ~ is_promotion * kvartal, data = dt_dd)
```

Residuals:

Min	1Q	Median	3Q	Max
-6.3781	-1.2924	-0.9473	1.0527	21.6219

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.947298	0.009539	99.309	< 0.0000000000000002 ***
is_promotion	-0.312574	0.047917	-6.523	0.000000000069 ***
kvartalQ2	0.345098	0.013490	25.582	< 0.0000000000000002 ***
kvartalQ3	0.603035	0.013492	44.697	< 0.0000000000000002 ***
kvartalQ4	0.296555	0.013492	21.981	< 0.0000000000000002 ***
is_promotion:kvartalQ2	4.234291	0.062132	68.150	< 0.0000000000000002 ***
is_promotion:kvartalQ3	5.140302	0.062157	82.699	< 0.0000000000000002 ***
is_promotion:kvartalQ4	2.394815	0.062149	38.534	< 0.0000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.069 on 198748 degrees of freedom

Multiple R-squared: 0.1399, Adjusted R-squared: 0.1399

F-statistic: 4618 on 7 and 198748 DF, p-value: < 0.0000000000000002

V linearnem modelu, ki je izgledal kot `Total Flights ~ is_promotion * kvartal`, smo dobili statistično značilne čisto vse interakcijske člene, kar nam potrjuje, da je promocijska skupina rasla hitreje od tega, kar bi pričakovali samo na podlagi sezonskega trenda. Posledice promocije so bile torej povezane z dejansko spremembo vedenja, ne le z drugačno sestavo strank. Če bi bile te interakcije neznačilna, bi to pomenilo, da je celotna razlika med skupinama pojasnjena s splošnim trendom (sezonskostjo) in stalnimi razlikami med skupinama, ne pa z učinkom promocije samim. Poglejmo si še povprečno mesečno število letov po kvartalnih in po promocijski skupini.

5.2 Faktorji, ki vplivajo na engagement

Sedaj pa nas zanimajo še faktorji, ki vplivajo na angažiranost v programu zvestobe. Odločili smo se, da bomo pogledali model, kjer bo odvisna spremenljivka vsota števila letov v letu 2018, ko so se vključili že člani promocije. Ker je bila odvisna spremenljivka `total_flights_sum` definirana kot skupno število letov posameznega člana v opazovanem obdobju, smo za napovedovanje angažiranosti uporabili model takšne podatke, pri čemer smo namesto linearne regresije uporabili negativno binomsko regresijo.

Pri problem so bile manjkajoče vrednosti pri spremenljivki `Salary`, ki so se v večinskem delu pojavljale pri

Table 5: Povprečja po kvartalih

Enrollment Type	kvartal	povp_flights	n
2018 Promotion	2018_Q1	0.6347244	1941
2018 Promotion	2018_Q2	5.2141136	2905
2018 Promotion	2018_Q3	6.3780614	2899
2018 Promotion	2018_Q4	3.3260945	2901
Standard	2017	1.1683372	188366
Standard	2018_Q1	0.9472979	47038
Standard	2018_Q2	1.2923957	47039
Standard	2018_Q3	1.5503329	47017
Standard	2018_Q4	1.2438532	47016

vrednosti College spremenljivke **Education**. To nas je prepričalo, da moramo najprej pogledati povezanost teh dveh, saj morda **Salary** sploh ni nujna spremenljivka za vključitev v model.

Najprej smo preverili povezanost z **Education** in ugotovili zelo močno statistično značilno povezavo (ANOVA: $F = 5048$, $p < 0,001$). Zaradi tega bi imputacija plač za to skupino zahtevala precej močne predpostavke in bi lahko v model vnesla umetno informacijo. Nato smo preverili, ali **Salary** poleg **Education** sploh prispeva dodatno napovedno vrednost v modelu. Na istem vzorcu 12.464 članov z znano plačo smo primerjali model z **Education** in ostalimi demografskimi značilnostmi z razširjenim modelom, ki je vključeval tudi **Salary**.

Model brez **Salary** je imel nižji AIC, poleg tega pa **Salary** v razširjenem modelu ni bil statistično značilen ($p = 0,954$). Rezultati zato kažejo, da po upoštevanju **Education** in ostalih značilnosti **Salary** ne prinaša pomembne dodatne informacije za napoved števila letov. Na podlagi tega smo se odločili, da **Salary** iz modela izključimo in se tako izognemo nezanesljivi imputaciji manjkajočih vrednosti, pri čemer **Education** ostane kot bolj robusten in popoln prediktor.

	Estimate	Std. Error	z value
(Intercept)	3.836649258	0.010271966	373.5068053
EducationCollege	0.007668197	0.004818094	1.5915418
EducationDoctor	-0.032707030	0.009612614	-3.4025114
EducationHigh School or Below	0.019929095	0.008939156	2.2294157
EducationMaster	0.029024939	0.011255756	2.5786751
ProvinceBritish Columbia	-0.012331861	0.008688698	-1.4192990
ProvinceManitoba	-0.061437688	0.012707716	-4.8346758
ProvinceNew Brunswick	0.006282188	0.012427312	0.5055146
ProvinceNewfoundland	-0.063095008	0.017345179	-3.6376107
ProvinceNova Scotia	-0.031288363	0.013538303	-2.3110993
ProvinceOntario	-0.016472253	0.008556422	-1.9251333
ProvincePrince Edward Island	-0.089603679	0.033328538	-2.6884971
ProvinceQuebec	-0.035021683	0.008955713	-3.9105411
ProvinceSaskatchewan	-0.021094164	0.014405555	-1.4643076
ProvinceYukon	0.024078164	0.023640342	1.0185201
`Marital Status`Married	0.004974442	0.005501436	0.9042080
`Marital Status`Single	0.012624936	0.006358408	1.9855499
`Enrollment Type`Standard	-1.114996771	0.005183847	-215.0906190
	Pr(> z)		
(Intercept)	0.000000000000		
EducationCollege	0.111487702643		
EducationDoctor	0.000667695581		
EducationHigh School or Below	0.025786255889		
EducationMaster	0.009918000630		

ProvinceBritish Columbia	0.155811873333
ProvinceManitoba	0.000001333628
ProvinceNew Brunswick	0.613197444984
ProvinceNewfoundland	0.000275178921
ProvinceNova Scotia	0.020827368080
ProvinceOntario	0.054212679454
ProvincePrince Edward Island	0.007177445743
ProvinceQuebec	0.000092089591
ProvinceSaskatchewan	0.143109914305
ProvinceYukon	0.308430841269
`Marital Status`Married	0.365885138914
`Marital Status`Single	0.047083323261
`Enrollment Type`Standard	0.000000000000

Theta: 252898.6

SE(theta): NaN

AIC: 189236.6

Osnovni model kaže, da je **Enrollment Type** daleč najmočnejši napovednik števila letov, saj je koeficient pri **Enrollment TypeStandard** enak -1.115 ($p < 0.001$), kar pomeni ($\exp(-1.115) \approx 0.33$), da standardni člani v povprečju letijo le tretjino toliko kot promocijski, ob nespremenjenih ostalih značilnostih.

Demografske spremenljivke imajo v primerjavi s tem bistveno šibkejši učinek. Izobrazba je delno značilna (doktorat ima nekoliko manj poletov, srednja šola ali manj in magisterij pa nekoliko več, $p < 0.05$), a učinki so majhni v primerjavi s tipom vpisa. Spremenljivka **Province** kaže nekaj značilnih negativnih odstopanj (Manitoba, Newfoundland, Nova Scotia, PEI, Quebec letijo manj kot referenčna provinca). Zakonski stan ni relevanten napovednik.

Zanimalo nas je tudi, kaj bi se zgodilo, če bi v model dodali spremenljivko kot je število zbranih točk, ki je do neke mere direktno povezana z številom letov, vendar bi lahko rekli, da odraža prejšnje navade letenja. Pogledali smo si še to in za oba modela izračunali primerljivo metriko R^2 .

	Estimate	Std. Error	z value
(Intercept)	0.13128240345	0.0385040385967	3.409574897
EducationCollege	0.01479993849	0.0109265395559	1.354494569
EducationDoctor	-0.00592456670	0.0212564435144	-0.278718625
EducationHigh School or Below	-0.01506180404	0.0204970295624	-0.734828624
EducationMaster	0.00643684296	0.0252605893477	0.254817608
ProvinceBritish Columbia	-0.00609266586	0.0195373847632	-0.311846541
ProvinceManitoba	-0.05446207546	0.0280594955025	-1.940949917
ProvinceNew Brunswick	0.00008364134	0.0280675141451	0.002980005
ProvinceNewfoundland	-0.02193450409	0.0387555987114	-0.565969946
ProvinceNova Scotia	-0.01581137155	0.0300896606214	-0.525475237
ProvinceOntario	-0.01534151466	0.0192079686241	-0.798705733
ProvincePrince Edward Island	-0.05851514585	0.0712529397644	-0.821231321
ProvinceQuebec	-0.01118046277	0.0201384294005	-0.555180473
ProvinceSaskatchewan	-0.02323145315	0.0325076158422	-0.714646477
ProvinceYukon	0.03277265858	0.0545831532071	0.600417100
`Marital Status`Married	-0.00210053409	0.0124430531247	-0.168811792
`Marital Status`Single	-0.01007948438	0.0144208496181	-0.698952187
`Enrollment Type`Standard	1.55703712188	0.0279351781191	55.737504706
points_accumulated	0.00003829044	0.0000002464017	155.398466410
	Pr(> z)		
(Intercept)	0.0006506421		

EducationCollege	0.1755786448
EducationDoctor	0.7804607682
EducationHigh School or Below	0.4624438719
EducationMaster	0.7988639748
ProvinceBritish Columbia	0.7551571520
ProvinceManitoba	0.0522643525
ProvinceNew Brunswick	0.9976223033
ProvinceNewfoundland	0.5714142115
ProvinceNova Scotia	0.5992528632
ProvinceOntario	0.4244610617
ProvincePrince Edward Island	0.4115145191
ProvinceQuebec	0.5787712237
ProvinceSaskatchewan	0.4748275179
ProvinceYukon	0.5482282940
`Marital Status`Married	0.8659446830
`Marital Status`Single	0.4845819116
`Enrollment Type`Standard	0.0000000000
points_accumulated	0.0000000000

Theta: 4.476037

SE(theta): 0.07684113

AIC: 114987.4

	model	pseudo_R2
1	Osnovni (brez points)	0.2289489
2	Razširjen (s points_accumulated)	0.4917982

Z dodano spremenljivko **Points Accumulated**, se je model precej spremenil. Koeficient pri njej je majhen (0.0000383), a zelo značilen ($p < 0.001$), kar ni presenetljivo, saj so točke izpeljane iz razdalje, ta pa skoraj popolnoma korelira s poleti ($r = 0.97$).

Najbolj opazna posledica je, da koeficient pri **Enrollment TypeStandard** spremeni predznak (+1.557, $p < 0.001$). To ni vedenjska ugotovitev, ampak mehanski artefakt, saj promocijski člani dobijo 1,5 točke/km, standardni le 1 (ugotovitev od prej), zato imajo pri enaki količini nabranih točk manj dejanskih poletov. Model to zazna kot navidezno “negativen” učinek promocije. Vzporedno večina demografskih spremenljivk izgubi značilnost, ker spremenljivka zbranih točk absorbira variabilnost, ki so jo prej pojasnjevale.

Osnovni model doseže McFadden psevd-R² = 0.229, razširjeni pa 0.492. Ti vrednosti nista neposredno primerljivi s klasičnim R², saj je pri McFaddenovi meri že 0.2–0.4 velja za dober do zelo dober model, zato ju ne smemo brati kot “nizki”.

Skok med modeloma gre pripisati skoraj izključno spremenljivki točk, ki je s poleti močno povezana. Zato ga ne smemo razlagati kot potrditev, da preteklo vedenje (Verhoef, 2003) bolje pojasni angažiranost, saj prave mere preteklega vedenja sploh nimamo. Bolj verodostojna ocena, koliko demografija in tip vpisa dejansko pojasnita variabilnost letenja, je zato psevd-R² osnovnega modela (0.229), ki ima, kot že rečeno, dobro vrednost.

5.2.1 Sklep

Analiza je pokazala, da je promocija 2018 najmočnejši in praktično edini pomemben dejavnik angažiranosti strank v vseh modelih (opisna statistika, diff-in-diff, Negativna Binoska). S svojo statistično značilnostjo je imela mnogo večji vpliv kot demografske značilnosti (plača, izobrazba, spol, zakonski stan), ki so se izkazale za bodisi neznailne, bodisi značilne, a z zanemarljivo majhnim učinkom. Promocijski člani tako letijo bistveno več od standardnih, ta razlika pa je delno posledica strukturnega bonusa pri nabiranju točk (1,5 namesto 1 točke/km) in dodatnih iz podatkov neopaznih ugodnosti, delno pa dejanske spremembe vedenja.

Analiza diff-in-diff namreč kaže, da je rast aktivnosti pri promocijski skupini presegla splošni sezonski trend, ki smo ga kontrolirali s pomočjo standardne skupine.

Hkrati promocija ni vplivala na dolgoročno vrednost strank (CLV) niti na koriščenje točk (redemption rate), kar je skladno s tem, da je verjetno ciljala predvsem na mehanizma statusa in navade (Henderson, Beck & Palmatier, 2011), ne pa na čustveno zavezanost (Verhoef, 2003), ki bi dolgoročno vrednost dvignila. Vzorec visoke aktivnosti, a nespremenje dolgoročne vrednosti se ujema tudi z ugotovitvijo, da demografske značilnosti pojasnijo presenetljivo malo variance v angažiranosti, kar potrjuje Verhoefovo (2003) tezo, da vedenje (ne pa kdo je stranka) poganja angažiranost.

Ker gre za opazovalne podatke, teh ugotovitev ne moremo interpretirati kot dokončen dokaz vzročnosti, saj enako verjetna razlaga ostaja, da je promocija privabila že bolj aktiven profil strank (samoselekcija), kar diff-in-diff kontrola za sezonskost zmanjša, a ne izniči povsem. Pri interpretaciji je treba upoštevati tudi, da v podatkih nimamo meritev nedenarnih (hedonskih, simbolnih, socialnih) koristi, za katere Mimouni-Chaabane in Volle (2009) trdita, da so ključne za dolgoročno zvestobo in kar bi lahko delno pojasnilo, zakaj se učinek promocije ne prenese na CLV. Prav tako je treba upoštevati, da analiza ne loči zares med kratkoročnim in dolgoročnim odzivom, saj podatki pokrivajo obdobje neposredno po uvedbi promocije. Za dokončnejši vzročni zaključek in oceno dolgoročne učinkovitosti bi bile potrebne longitudinalne podatke, ki bi segale dlje v prihodnost.

6 (Tristan) Identificirajte segmente strank z visoko vrednostjo in predlagajte možne ukrepe za optimizacijo

6.1 Osnovno oblikovanje segmentov glede na kvartile in priprava podatkov za analizo skupin

Cilj je, da stranke razdelimo v segmente in ugotovimo, kateri segmenti predstavljajo stranke z visoko vrednostjo in predlagamo ukrepe za optimizacijo. Eden izmed pristopov, ki se uporablja v literaturi, je segmentacija na podlagi vrednosti CLV (Customer Lifetime Value oziroma skupna vrednost stranke). CLV je mogoče uporabiti kot osnovo za oblikovanje segmentov, pri čemer stranke razvrstimo glede na njihovo relativno vrednost (*Lemon & Mark, 2008*). Zato najprej pogledamo netransformirano (nelogaritmirano) spremenljivko CLV in njeno porazdelitev, nato pa na njeni osnovi oblikujemo vrednostne segmente.


Poglejmo najprej opisne statistike spremenljivke CLV.

Table 6: Povzetek vrednosti CLV

Statistic	Value
Min.	1898.01
1st Qu.	3980.84
Median	5780.18
Mean	7988.90
3rd Qu.	8940.58
Max.	83325.38

Vidimo, da je najmanjša vrednost spremenljivke CLV 1898.01, največja pa kar 83325.38, zaradi velike razlike med povprečno vrednostjo spremenljivke 7988.90 in mediano 5780.18, lahko iz podatkov razberemo, da gre za asimetrično porazdelitev.

Porazdelitev CLV s kvartili



Grafično potrdimo, da je CLV močno desno asimetrična, kar pomeni, da je večina strank skoncentrirana pri nižjih vrednostih, medtem ko manjši delež strank dosega zelo visoke vrednosti. *Benoit in Van den Poel (2009)* opozarjata, da so porazdelitve CLV pogosto močno asimetrične in da je pri analizi posebej pomemben zgornji del porazdelitve, kjer se nahajajo najbolj vredne stranke. Zaradi tega je smiselno stranke razvrščati tudi glede na kvartile CLV.

Podoben koncept predstavlja Paretoev princip oziroma pravilo 80/20, po katerem lahko relativno majhen delež populacije prispeva nesorazmerno velik delež celotne vrednosti. *Newman (2004)* pri tem poudarja, da Paretoev princip ne velja samo za ekonomske pojave.

Kvartilna skupina glede na CLV	Število članov
Q1 (Najnižji)	4186
Q2 (Nizko-srednji)	4192
Q3 (Srednje-visoki)	4176
Q4 (Najvišji)	4183

Glede na kvartile smo oblikovali 4 skoraj enako velike skupine strank glede na njihov CLV (*Najnižji*, *Nizko-srednji*, *Srednje-visoki*, *najvišji*). Cilj je ugotoviti ali se tako oblikovane skupine, razlikujejo med seboj po vrednosti ostalih spremenljivk.

Table 8: Povprečni CLV po kvartilnih skupinah

Kvartilna skupina	Povprečni CLV
Q1 (Najnižji)	2905.17
Q2 (Nizko-srednji)	4949.02

Kvartilna skupina	Povprečni CLV
Q3 (Srednje-visoki)	7433.17
Q4 (Najvišji)	16677.48

Skupine se razlikujejo tudi po povprečni vrednosti CLV kot vidimo zgoraj v tabeli, vrednosti iz nižje v višjo skupino konsistentno naraščajo.

Spremenljivka, ki ima velik delež manjkajočih vrednosti (25.44%) je **Salary** (plača). Te vrednosti bi bilo smiselno imputirati. To je v statistiki postopek nadomeščanja manjkajočih podatkov z ocenjenimi ali izračunanimi vrednostmi.

Za imputacijo **Salary** bomo zaradi visokega deleža manjkajočih vrednosti in odvisnosti manjkajoče vrednosti od opazovane spremenljivke same uporabili kompleksnejši multivariatni imputacijski algoritem. Upoštevati moramo, da imajo pri tej spremenljivki, samo nekateri izmed tistih z izobrazbo *College*, manjkajoče vrednosti. Odločimo se za imputacijski algortiem imenovan *missRanger*, ki deluje po principu naključnih gozdov, kjer s pomočjo znanih vrednosti spremenljivke in pomožnih spremenljivk modelira ter nadomesti manjkajoče vrednosti. Uporabili bomo 1000 gozdov in 100 iteracij, da bodo napovedi čim bolj natančne.

Uvedemo tudi dve novi spremenljivki **Salary_Missing** (če je manjkal podatek o plači) in **churned** (ali je član še aktiven). Ti nama bosta pomagali pri kompleksnejšem oblikovanju skupin v nadaljevanju.

Kot smo videli že prej, imajo številni uporabniki pri mnogih spremenljivkah vrednost 0. Gre za t.i. "*Zero inflated*" porazdelitve (porazdelitve s presežnimi ničlami). Prav zato bi bilo dobro uvesti nove spremenljivke, ki bi merile ali je vrednost člana pri posamezni spremenljivki večja kot nič in je šlo za neko aktivnost, ali pa nasprotno te ni bilo, in je enaka nič.

Končajmo še z glavnim oblikovanjem novih spremenljivk, ki agregirajo posamezne numerične vrednosti in so za primerjavo med skupinami bolj smiselne.

Za vsako stranko smo torej na podlagi podatkov o posameznih interakcijah izračunali naslednje agregirane spremenljivke: (nekatero nam bodo pomagal kasneje pri uporabi strojnega učenja za segmentacijo)

1. Skupna aktivnost:

- skupno število opravljenih letov,
- skupna preletena razdalja,
- skupno število zbranih točk,
- skupno število porabljenih točk,
- skupna vrednost porabljenih točk.

2. Časovna aktivnost:

- število različnih mesecev, v katerih je bila stranka aktivna,
- število mesecev od zadnjega leta.

3. Povprečna mesečna aktivnost:

- za primerljivost strank z različnim številom aktivnih mesecev smo izračunali povprečne mesečne vrednosti.


4. Indikatorji aktivnosti:

- za spremenljivke, pri katerih se pojavljajo ničelne vrednosti, smo dodatno ustvarili binarne indikatorje, ki označujejo, ali je bila določena aktivnost sploh prisotna;
- indikatorje smo izračunali za lete, preleteno razdaljo, zbrane točke, porabljene točke in vrednost porabljenih točk.

5. Spremenljivke, ki merijo prisotnost aktivnosti:

- Če stranka ni zbrala nobene točke, smo vrednost nastavili na 0.
- Pri strankah brez opravljenih letov smo vrednost nastavili na 0.

Poglejmo še porazdelitve vseh teh, na novo oblikovanih, spremenljivk.



Vidimo, da so porazdelitve novih, nekaterih agregiranih spremenljivk še vedno asimetrične, trenutno ne bomo uporabili dodatnih transformacij, moramo pa zato biti pozorni katere teste uporabimo (parametrične ali neparametrične).

6.2 Analiza osnovnih skupin oblikovanih glede na kvantile

Poglejmo torej ali so prisotne razlike med osnovnimi skupinami oblikovanimi glede na kvantile. Najprej se lotimo nominalnih spremenljivk. Uporabili bomo *Hi-kvadrat* test, ki je neparametričen, in popravek (*FDR*) (False discover rate, delež lažnih odkritij) za večkratno testiranje. To je metoda, s katero pri večkratnih statističnih testiranjih omejimo delež lažnih odkritij, se pravi rezultatov, ki jih nepravilno označimo za statistično značilne. Stopnjo značilnosti določimo kot $\alpha = 0.10$ oz. 10%.





Table 9: Tabela p-vrednosti (Hi-kvadrat test, popravek FDR)

	p-vrednost (FDR)
Gender	0.7903
Education	0.0000
Marital Status	0.0101
Loyalty Card	0.0000
Enrollment Type	0.7415
Province	0.7903
City	0.7415
churned	0.7903
Salary_Missing	0.0000

Iz tabele p-vrednosti vidimo, da obstajajo statistični značilne razlike med nominalnimi spremenljivkami med skupinami pri: **Loyalty Card** (tip/nivo kartice zvestobe), **Education** (izobrazba), **Salary_Missing** (ali je

manjkal podatek o plači) in pogojno **Marital Status** (zakonski stan). Pri ostalih statistično značilne razlike ni zaznati.

Deleži kategorij po CLV kvartilih (značilne spremenljivke)



Poglejmo še grafičen prikaz teh spremenljivk, katerih vrednosti so statistično značilne med skupinami.

Pri spremenljivki **Loyalty Card** (nivo kartice zvestobe) vidimo, da v najnižjem CLV kvartilu (Q1) prevladuje kartica Star, Aurora je odsotna. V višjih kvartilih (Q3–Q4) se deleži vseh treh kartic izenačijo. Kartica najverjetneje dober napovednik vrednosti stranke. Seveda se je potrebno zavedati, da je nivo kartice zvestobe povezan s tem koliko jo stranka uporablja (večja poprava je nagrajena z višjim nivojem).


Education (izobrazba) je statistično značilne med skupinami. Razlike so, a zmerne: delež College rahlo pada, Bachelor narašča, Doctor/Master sta stabilna skozi skupine in majhna.

Salary Missing (ali plača manjka) je manj prisotna v Q4 in je več v Q2. Glede na ugotovitve, da manjka izključno pri visoko šolsko izobraženih (*Collage*) to ni toliko presenetljivo.

Pri **Martial Status** (zakonski stan) opazimo, da se delež samskih (*Single*) se rahlo znižuje od Q1 proti Q4, delež ločenih (*Divorced*) pa rahlo narašča.

Nadaljujmo še z številskimi vedenjskimi spremenljivkami. Predvidevamo lahko, da bodo nekatere med seboj zelo korelirane (tako osnovne kot tiste oblikovane naknadno), tako, da jih odstranimo. Namen je, da ne testiramo in vizualiziramo vse, saj merijo podobne aktivnosti.

Korelacijska matrika agregiranih vedenjskih spremenljivk



Na podlagi korelacijske matrike (in tabele stopnje korelacije spremenljivk) vidimo, da so nekatere spremenljivke med seboj močno korelirane. Cilj je, da izberem spremenljivke, ki imajo čim bolj nekorelirano vrednost z ostalimi, sicer lahko pri algoritmu *k-means* pride do napak. Zato izberemo nabor petih spremenljivk, ki merijo numerično čim bolj različne dimenzije vedenja (aktivnosti): **avg_flights_per_month** (povprečno število letov na mesec), **avg_distance_per_flight** (povprečna razdalja na let), **avg_points_accum_per_month** (povprečno število zbranih točk na mesec), **redemption_rate** (stopnja unovčitve točk) in **total_flights_sum** (vsi leti skupaj). Zadnjo kljub večji korelaciji z ostalimi ohranimo, saj je pomemben indikator aktivnosti.




Table 10: ANOVA za izbrane vedenjske spremenljivke glede na kvartilno skupino CLV

Spremenljivka		F-statistika	df	p-vrednost	Bonferroni p
avg_flights_per_month	avg_flights_per_month	0.464	3, 16733	0.7076	1
avg_distance_per_flight	avg_distance_per_flight	0.183	3, 16733	0.9078	1
avg_points_accum_per_month	avg_points_accum_per_month	0.957	3, 16733	0.4122	1
redemption_rate	redemption_rate	1.047	3, 16733	0.3705	1
total_flights_sum	total_flights_sum	0.130	3, 16733	0.9422	1

Poglejmo zdaj še to kako se skupine oblikovane po CLV kvartilih razlikujejo med seboj: - Q1 (najnižji CLV): podpovprečne vrednosti pri vseh spremenljivkah razen rahlo nadpovprečno vnovčevanju točk in povprečne razdalje na let. Malo letijo, malo zbirajo točk in prevozijo malo km, a nadpovprečno unovčijo zbrane točke (visoka stopnja unovčitve). - Q2 (nizko-srednji): podoben trend kot Q1, ampak nekoliko višje vrednosti (večinoma podpovprečne vrednosti). - Q3 (srednje-visoki): nadpovprečne vrednosti pri vseh spremenljivkah razen unovčevanja točk in skupnega števila letov. Q4 (najvišji CLV): presenetljivo nižje povprečne vrednosti kot Q3, povprečna razdalja na let je celo najnižja, prav tako vnovčevanje točk (oboje podpovprečno), imajo nadpovprečno skupno število letov in prav največ med vsemi skupinami.

Višji CLV ni povezan z več pogostostjo ali unovčevanjem točk, temveč z višjo “vrednostjo” posameznih letov (razdalja, obseg). Vidimo tudi, da sta si skupini z Q1 (najnižji CLV) in Q2 (nizko-srednji) zelo podobni, mogoče lahko to uporabimo v prihodnji analizi segmentiranja z strojnim učenjem za določanje števila skupin. Seveda v primeru, če bo optimalno število skupin, drugačno kot tukaj.

Vendar pa kljub temu, da so na grafu vidne jasne razlike, ne moremo trditi, da gre za statistično značilne razlike. Na to nakazuje tabela p - vrednosti, saj hipoteze, da so med skupinami pristone razlike ob $\alpha = 0,10$

ne zavrznemo. Vseeno uporabimo rezultate za usmiritev in nadaljno raziskovanje. Tokrat smo uporabili Bonferonijev popravek (strožjo kot FDR).


6.3 Oblikovanje segmentov s pomočjo strojnega učenja in priprava podatkov za analizo skupin

Zanimivo bi bilo preveriti, če lahko s pomočjo strojnega učenja določimo skupine glede na vedenje (vedenjske spremenljivke od prej, brez CLV) in dobimo podobne kot v prejšnjem podpoglavju ali pa različne.

Uporabili bomo algoritem *k* najbližjih sosedov (*k-means*). To je metoda, ki spada pod nenadzorovano učenje, saj iščemo skrite vzorce v podatkih. V našem primeru s pomočjo Evklidske razdalje, ki meri razdaljo med enotami glede na vrednosti pri posamezni izbrani spremenljivki. Želimo, da so enote v skupini notranjo homogene hkrati pa čim bolj različne med skupinami samimi.


Kot smo videli prej je smiselno zaradi *k-means* algoritma (in Evklidske razdalje), ki predpostavlja iste porazdelitve in oblike skupin, uporabiti logaritmirane vrednosti (desno asimetričnih spremenljivk) in jih skalirati (standardizirati).

Elbow



Za določitev števila skupin lahko uporabimo princip iskanja komolca (*elbow plot*), kjer iščemo prelom, ta se pojavi med 3 in 4. Zaradi ugotovitve, da sta si bili skupini Q1 (najnižji CLV) in Q2 (nizko srednj CLV) v prejšnjem podpoglavju zelo podobni pri vseh izbranih vedenjskih spremenljivkah, izberemo torej 3 skupine.

Poglejmo še povprečne vrednosti izbranih vedenjskih spremenljivk na originalni (nelogitmirani skali) po skupinah oblikovanih s *k-means* algoritmom.



Vidimo, da je ima skupina 1 podobne povprečne vrednosti spremenljivk kot sta to imeli skupini Q1 (najnižji CLV) in Q2 (nizko srednj CLV) v prejšnjem podpoglavju, vrednosti vseh spremenljivk ima močno podpovprečne za razliko od segmentacije v prejšnjem poglavju, kjer so vsaj točke nadpovprečno vnovčevali. To so torej uporabniki, ki verjetno občasno letijo in ne koristijo ugodnosti. Skupina 2 je nekoliko podobna Q4 (najvišji CLV), to so uporabniki, ki imajo pri vseh spremenljivkah nadpovprečne vrednosti razen pri vnovčevanju točk. Potem pa imamo še 3 skupino, ta je nekoliko analogna Q3 (srednje-visok CLV), kjer je nadpovprečno uporabniki vnovčujejo točke in letijo na daljše razdalje (nadpovprečna vrednost), skupno število letov pa imajo podpovprečno kot tudi zbranih točk na mesec.

Table 11: ANOVA – razlike med K-means segmenti (Bonferroni)

	Spremenljivka	F_stat	df	p_value	Bonferroni_p
avg_flights_per_month	avg_flights_per_month	5619.896	2, 16734	0.000000	0.0000
avg_distance_per_flight	avg_distance_per_flight	32560.415	2, 16734	0.000000	0.0000
avg_points_accum_per_month	avg_points_accum_per_month	2485.322	2, 16734	0.000000	0.0000
redemption_rate	redemption_rate	522.324	2, 16734	0.000000	0.0000
total_flights_sum	total_flights_sum	20083.223	2, 16734	0.000000	0.0000
CLV	CLV	2.599	2, 16734	0.074391	0.8183
Salary	Salary	0.187	2, 16734	0.829234	1.0000
active_months	active_months	118.346	2, 16734	0.000000	0.0000
total_distance	total_distance	16676.264	2, 16734	0.000000	0.0000
points_accumulated	points_accumulated	10093.233	2, 16734	0.000000	0.0000
points_redeemed	points_redeemed	1791.851	2, 16734	0.000000	0.0000


Preverimo še, če se skupine med seboj razlikujejo po ostalih spremenljivkah. Prvih 5 spremenljivk (avg_flights_per_month (Povpr. letov na mesec), avg_distance_per_flight (Povpr. razdalja na let),

`avg_points_accum_per_month`(Povpr. zbranih točk na mesec), `redemption_rate`(Stopnja unovčitve točk), `total_flights_sum`(Skupno število letov)) se sicer med skupinam statistično značilno razlikuje, ampak je to zgolj preverjanje ali algoritem deluje prav, saj so bile le te spremenljivke uporabljene za segmentacijo. Bolj zanimivo je, da se povprečne vrednosti `CLV` in `Salary` med skupinami ne razlikujeta statistično značilno. Spremenljivke `active_months`, `total_distance`, `points_accumulated`, `points_redeemed` pa se med skupinami razlikujejo statistično značilno. Sicer gre tudi tukaj za nekoliko korelirane spremenljivke s tistimi uporabljenimi za segmentiranje, a vseeno je to zanimiva informacija.

Poglejmo še kako se dobljene skupine razlikujejo po nominalnih spremenljivkah.

Table 12: Tabela p-vrednosti (Hi-kvadrat test, popravek FDR)

	p-vrednost (FDR)
Gender	0.3356608
Education	0.3356608
Marital Status	0.2392377
Loyalty Card	0.8588208
Enrollment Type	0.0000000
Province	0.3206363
City	0.5675447
churned	0.0000000
Salary_Missing	0.2392377



Iz Hi-kvadrat testa (tabela) se je pokazalo, da se segmenti statistično značilno razlikujejo tudi po spremenljivkah `Enrollment Type` (način vstopa v program) in `churned` (odliv). Prav tako to jasno vidimo na grafu.

Pri spremenljivki `Enrollment Type` opazimo, da je delež strank, vpisanih preko promocije 2018, največji v segmentu 2 (najbolj aktivna, najvišje vredna skupina), najmanjši pa v segmentu 3. To je skladno z

ugotovitvijo, da so promocijsko pridobljene stranke v povprečju bolj aktivne letalke.

Precej bolj izrazite so razlike pri spremenljivki **churned**. Segment 1 ima zelo visoko stopnjo odliva (skoraj 60 %), segment 3 zmerno (okoli 25 %), segment 2 pa izjemno nizko (le nekaj odstotkov). Pri slednjih gre torej za jedro najbolj zvestih strank. Vzorec je smiseln glede na profil segmentov: manj aktivne stranke (segment 1) najlažje zapustijo program, najbolj aktivne (segment 2) pa ostajajo. To nakazuje, da bi bilo smiselno retencijske ukrepe usmeriti predvsem v segment 1.

6.4 Zaključki in priporočila

Analiza segmentacije strank z visoko vrednostjo je pokazala pomembno razhajanje (a tudi nekatere podobnosti) med dvema pristopoma: segmentacijo na podlagi neposredne vrednostne mere (CLV) in segmentacijo na podlagi vedenjskih spremenljivk (*k-means*). Skupini, oblikovani po CLV kvartilih, in skupine, oblikovane s *k-means* algoritmom na podlagi vedenja, se le delno prekrivajo (CLV in **Salary** se med *k-means* segmenti ne razlikujeta značilno). *Chen, Liu, Zheng in Li (2023)* opozarjajo, da RFM (Recency, Frequency in Monetary Value oziroma nedavnost, pogostost in denarna vrednost) modeli temeljijo na pretekli transakcijski aktivnosti, medtem ko je CLV usmerjen v prihodnost in implicitno povezan z RFM, a ne enak konceptu. Naša ugotovitev, da najvišji CLV kvartil (Q4) ni nujno enak najbolj aktivnemu vedenjskemu segmentu smo opazili tudi na našem primeru (v literaturi že znano).

Druga ključna ugotovitev je nizka stopnja vnovčitve točk (**redemption_rate**) pri strankah z najvišjim CLV (Q4) in pri vedenjskem segmentu z visoko aktivnostjo (segment 2), medtem ko imajo stranke z nižjim CLV in nizko aktivnostjo relativno višjo stopnjo vnovčitve. Ta vzorec je skladen z ugotovitvami *Goić, Montoya in Troncoso (2025)*, ki na podatkih letalskega programa zvestobe pokažejo, da prav intenzivni, pogosti letalci pogosto kopičijo velike količine točk, ki jih sorazmerno redkeje unovčijo, avtorji pa poudarjajo, da je za zmanjšanje te vrzeli učinkoviteje spodbujati pogostejše, manjše vnovčitve kot pa ponujati zgolj nagrade, ki zahtevajo veliko število točk. Podobno *Danaher, Sajtos in Danaher (2020)* na longitudinalnih podatkih programa zvestobe pokažejo, da vnovčitev nagrade člane spodbudi k povečanju nakupne pogostosti in deleža potrošnje znotraj programa, kar članom pomaga preiti iz manj aktivnega v bolj aktivno "stanje". Slednje odpira vprašanje, ali bi bolj dostopne oz. pogostejše priložnosti za vnovčitev za najvrednejši segment (Q4/segment 2) povečale njihovo zavzetost in dolgoročno zvestobo, namesto da nevnovčene točke obravnavamo zgolj kot "prihranek" podjetja.

Iz tega izhajajo naslednja priporočila za optimizacijo programa zvestobe:

1. **Ločeno obravnavanje CLV- in vedenjske segmentacije.** Ker se skupini ne prekrivata popolnoma, priporočamo, da se marketinške akcije ne načrtujejo zgolj na podlagi ene same segmentacijske sheme, temveč se kombinirajo obe perspektivi – vrednostna (CLV) za določanje prioritete vlaganja virov in vedenjska (*k-means*) za določanje vsebine in časa komunikacije. Lahko pa pri obeh izhajamo iz 3 skupin, ki so se izkazale za optimalne (pri 4 skupinah sta si dve vedenjsko zelo podobni).
2. **Spodbujanje pogostejših, manjših vnovčitev pri visoko aktivnih strankah.** Glede na to, da najbolj aktivni uporabniki (visoko **total_flights_sum**, visoka **avg_distance_per_flight**) najmanj vnovčujejo točke, bi uvedba dodatnih, lažje dosegljivih nagrad lahko povečala pogostost vnovčitve in s tem angažiranost teh strank, saj *Goić et al. (2025)* ugotavljajo, da pogostejše vnovčitve bolj učinkovito deluje kot dražje, redkeje dosegljive nagrade, *Danaher et al. (2020)* pa dodajajo, da vnovčitev sama po sebi spodbuja nadaljnjo aktivnost člana.
3. **Ciljno spodbujanje segmenta Q1–Q2 (nizek CLV, a razmeroma visoka stopnja vnovčitve).** Te stranke aktivno izkoriščajo ugodnosti programa, a imajo nizko skupno vrednost – primerne so za akcije, ki spodbujajo pogostejše letenje (na primer bonus točke za dodatne lete), saj gre za segment, ki se najbolj odziva na spodbude za povečanje frekvence.
4. **Nadgradnja statusa kartice zvestobe kot napovednika vrednosti.** Ker je **Loyalty Card** statistično značilno povezana s CLV kvartilom, priporočamo nadaljnjo analizo, ali bi dodaten (peti) nivo kartice ali prilagojene ugodnosti znotraj obstoječih nivojev dodatno diferencirale najvišji segment.

Pri vsem tem pa ne smemo pozabiti, da je omejitev naše analize, da gre za presečne (obstoječe) podatke in tako ne moremo sklepati o vzročnosti med vedenjem in vrednostjo stranke, temveč zgolj o korelacijskih vzorcih. Zato bi bila potrebna posebno oblikovana študija, kjer bi preverjali znanstveno hipotezo oziroma hipoteze.

7 (Patricija) Napovedovanje odliva strank oziroma odpovedi ter predlaganje —


8 možnih ukrepov za njihovo zadržanje

8.1 Definiranje churn

Za začetek, dodamo novo spremenljivko **Churn**, ki je binarna, toraj zavzema vrednosti 0 in 1. 1 pomeni da je stranka prekinila članstvo in 0 da članstva ni zapustila.

V nadaljevanju smo pogledali podatke in ugotovili, da je članstvo zapustilo 2067 oseb, kar predstavlja 12% vseh kartičarjev.

Churn	n	%
0	14670	88
1	2067	12



8.2 Pregled in analiza spremenljivk

V nadaljevanju pogledamo osnovne statistične lastnosti spremenljivk. Najprej združimo podatke iz obeh tabel. Dobili smo tabelo “merged”, ki je longitudinalna tabela torej 1 kartičar x več mesecev. Za napovedovanje v nadaljevanju pa želimo, da posamezna vrstica predstavlja posameznega kartičarja.

V nadaljevanju naredimo analizo vsake spremenljivke. Spremenljivke ločimo najprej na numerične in kategorične in jih obravnavamo ločeno.



8.2.1 Numerične spremenljivke

Najprej določimo numerične spremenljivke, ki jih v nadaljevanju analiziramo. Za vsako spremenljivko izračunamo povprečje, mediano in standardni odklon pri različnih vrednostih stolpca **Churn**.


```
# A tibble: 14 x 6
  variable      Churn      n    mean median      sd
  <chr>      <dbl> <int>  <dbl>  <dbl>  <dbl>
1 Salary      0 14670 79438.  73530 34762.
2 Salary      1  2067 79371.  73193 34494.
3 CLV         0 14670 7969.   5776. 6805.
4 CLV         1  2067 8132.   5793. 7248.
5 Total Flights 0 78640   2.79    2    2.68
6 Total Flights 1  5773   2.30    2    3.15
7 Distance     0 184004 3911.   3060 3619.
8 Distance     1  8568 3647.   2406 4729.
9 Points Accumulated 0 184004 4074.   3081 4578.
10 Points Accumulated 1  8568 4047.   2437 6530.
11 Points Redeemed 0 37274  312.    394  269.
12 Points Redeemed 1  2929  152.     0  245.
13 Dollar Cost Points Redeemed 0 37075  56.1    71  48.5
14 Dollar Cost Points Redeemed 1  2925  27.3     0  44.1
```

Pri spremenljivki **Salary** so razlike med skupinama majhne, medtem ko so pri **CLV** razlike nekoliko bolj izrazite. Na podlagi opisne analize lahko govorimo o razlikah med skupinama, ne moremo pa še sklepati o vzročnem vplivu posamezne spremenljivke na churn.


Podobno kot zgornja tabela, prikazuje tudi spodnji graf. Pri **Points Redeemed** je pri strankah, ki so odpovedale članstvo, opazna večja koncentracija nizkih vrednosti. Pri višjih vrednostih se porazdelitvi skupin bolj razlikujeta, pri čemer je med strankami, ki so ostale v programu, več strank z višjim številom unovčenih točk. To nakazuje na možno povezavo med uporabo programa in vztrajanjem v programu.




Distribution of Total Flights by churn




Distribution of Distance by churn




Distribution of Points Accumulated by churn



Distribution of Points Redeemed by churn



Distribution of Dollar Cost Points Redeemed by churn







8.3 Kategorične spremenljivke


Za kategorične spremenljivke najprej izračunamo število strank znotraj posamezne vrednosti izbrane spremenljivke in delež strank, ki so odšle iz programa zvestobe. Ta delež mora biti primerljiv pri vseh vrednostih izbrane spremenljivke, da lahko ustrezno primerjamo rezultate.

A tibble: 15 x 5

	category	customers	churned	churn_rate	variable
	<chr>	<int>	<dbl>	<dbl>	<chr>
1	Female	8410	1055	12.5	Gender
2	Male	8327	1012	12.2	Gender
3	Bachelor	10475	1286	12.3	Education
4	College	4238	527	12.4	Education
5	Doctor	734	96	13.1	Education
6	High School or Below	782	93	11.9	Education
7	Master	508	65	12.8	Education
8	Divorced	2518	291	11.6	Marital Status
9	Married	9735	1214	12.5	Marital Status
10	Single	4484	562	12.5	Marital Status
11	Aurora	3429	449	13.1	Loyalty Card
12	Nova	5671	717	12.6	Loyalty Card
13	Star	7637	901	11.8	Loyalty Card
14	2018 Promotion	971	115	11.8	Enrollment Type
15	Standard	15766	1952	12.4	Enrollment Type







Razlike v churn rate med kategorijami posameznih demografskih spremenljivk so relativno majhne. To nakazuje, da demografske značilnosti v tej eksploratorni analizi nimajo tako izrazite povezave s churnom kot spremenljivke, povezane z aktivnostjo strank.

8.3.1 Aktivnost strank

Za nadaljno analizo je pomembna tudi aktivnost strank. Spodaj izračunamo osnovne statistične vrednosti spremenljivk, ki odražajo aktivnost strank.

```
# A tibble: 2 x 5
  Churn mean_flights median_flights mean_distance mean_points
<dbl>   <dbl>         <dbl>         <dbl>         <dbl>
1     0     1.42           1           2125.         2213.
2     1     0.431         0            651.          722.
```


8.3.2 Korelacije med spremenljivkami

Za nadaljno napovedovanje je pomembno ugotoviti morebitne odvisnosti in korelacije med spremenljivkami.

	Salary	CLV	Total Flights	Distance
Salary	1.000000000	-0.021657467	-0.003306861	-0.003229269
CLV	-0.021657467	1.000000000	-0.003598681	-0.002886825
Total Flights	-0.003306861	-0.003598681	1.000000000	0.908788881
Distance	-0.003229269	-0.002886825	0.908788881	1.000000000
Points Accumulated	-0.006868886	-0.002482686	0.893329184	0.977665157
Points Redeemed	0.002087359	0.000275034	0.155633378	0.140444557

	Points Accumulated	Points Redeemed
Salary	-0.006868886	0.002087359
CLV	-0.002482686	0.000275034


Total Flights	0.893329184	0.155633378
Distance	0.977665157	0.140444557
Points Accumulated	1.000000000	0.122519678
Points Redeemed	0.122519678	1.000000000




Zgornji grafikon prikazuje korelacijo med spremenljivkami. Opazno je, da so spremenljivke **Total flights**, **Distance**, **Points accumulated** in **Points Redeemed** med sabo močno pozitivno korelirane, kar je glede na opis spremenljivk tudi smiselno.

8.3.3 Pregled časovne vrste odhodov strank iz programa zvestobe


V nadaljevanju prikažemo vizualni pregled in analizo odhodov strank glede na časovno komponento.



Zgornji linijski grafikon prikazuje, da se število odhodov povečuje skozi leta. Največji skok je opazen v drugi polovici leta 2018.



Zgornji grafikon prikazuje porazdelitev odhodov iz programa zvestobe po mesecih v letu. Iz grafa opazimo, da je največ odhodov v poletnih mesecih in v zadnjih dveh mesecih v letu. Opazna je torej neka sezonska komponenta.




Zgornji grafikon je zelo poveden, saj je možno opaziti vzorec, in sicer je vidno, da večina kartičarjev odide po 1 letu. Največ kartičarjev je zapustilo program zvestobe v letu 2015. Opazimo tudi da se povečuje delež kartičarjev, ki odidejo v istem letu kot so se včlanili. Za vpisane v program zvestobe v letu 2018 pa je nekoliko problematično za neposredno primerjavo, saj ne vemo ali so osebe vpisane v članstvo odšle po 1 letu.

8.3.4 Čas odhoda v mesecih

V podatkovno tabelo smo dodali novo spremenljivko `tenure months`, ki ponazarja kolikšna je razlika v mesecih med odhodom iz članstva in mesecih vstopa v članstvo.

Churned customers by number of months



Glede na zanimive rezultate pri preklicu programa zvestobe po letih, nas je zanimalo ali opazimo vzorec tudi po mesecih. Zgornji grafikon prikazuje po koliko mesecih so stranke odšle iz programa zvestobe. V podatkih je opazen izrazitejši vrh odpovedi približno osem mesecev po včlanitvi. Manjši skok je viden pri zadnjem stolpcu, ki prikazuje agregirano število izstopov iz programa zvestobe. Podatke za zadnji stolpec smo agregirali zaradi večje preglednosti grafikona, sicer so vrednosti dokaj enakomerno porazdeljene po mesecih.

8.4 Ugotovitve eksploratorne analize

Na podlagi eksploratorne analize so največje razlike med strankami, ki so članstvo preklicale, in tistimi, ki so v programu ostale, opazne pri spremenljivkah, ki odražajo njihovo aktivnost. Stranke z večjim številom letov, večjo preleteno razdaljo in večjim številom pridobljenih oziroma unovčenih točk se med skupinama razlikujejo bolj izrazito kot glede na demografske značilnosti, kot so spol, izobrazba ali zakonski stan.

Med spremenljivkami, povezanimi z aktivnostjo, so prisotne tudi močne pozitivne korelacije. To je pričakovano, saj večja letalska aktivnost praviloma pomeni večjo preleteno razdaljo ter posledično večje število pridobljenih točk. Hkrati je ta ugotovitev pomembna za nadaljnje modeliranje, saj lahko močno korelirane spremenljivke vsebujejo redundantne informacije in povzročijo težave pri interpretaciji modela.

Pri unovčevanju točk je opazna povezava med večjo uporabo zbranih točk in večjim vztrajanjem v programu. To lahko nakazuje, da aktivna uporaba ugodnosti programa prispeva k večji angažiranosti članov. Vendar na podlagi eksploratorne analize še ne moremo sklepati o vzročnem vplivu, zato bo to povezavo smiselno preveriti tudi z napovednim modelom.

Časovna analiza dodatno kaže, da se velik del odpovedi pojavi relativno kmalu po včlanitvi. Pri tem je posebej zanimivo obdobje prvih mesecev članstva, zato je lahko zgodnja aktivnost stranke pomemben dejavnik pri napovedovanju kasnejšega churn-a. Pri interpretaciji strank, včlanjenih proti koncu opazovalnega obdobja, je potrebna previdnost, saj zanje nimamo enako dolgega obdobja spremljanja.

Na podlagi teh ugotovitev se kot ena izmed možnih zadrževalnih strategij kaže usmerjanje ukrepov predvsem v manj aktivne oziroma nove člane. Letalsko podjetje bi lahko na primer ponudilo dodatne točke ali druge ugodnosti članom, ki v prvih mesecih po včlanitvi ne izkazujejo aktivnosti. Namen takšnega ukrepa bi bil povečati uporabo programa, spodbuditi nadaljnje letenje in povečati verjetnost dolgoročnega vztrajanja v programu.

8.5 Napovedovanje odliva strank

Za potrebe napovedovanja smo longitudinalno tabelo merged, v kateri je za posameznega kartičarja zabeležena največ ena vrstica za posamezen mesec, preoblikovali na raven posameznega kartičarja. Ker je ciljna spremenljivka Churn definirana na ravni kartičarja, mora tudi modelna podatkovna tabela vsebovati eno vrstico za vsakega kartičarja. Mesečne podatke o letalski aktivnosti smo zato agregirali.

Poleg absolutnega števila unovčenih točk smo oblikovali tudi relativni kazalnik redemption_rate, ki predstavlja delež akumuliranih točk, ki jih je stranka unovčila. S tem smo želeli razlikovati med strankami z različno intenzivnostjo zbiranja točk, saj enako število unovčenih točk nima enakega pomena pri stranki, ki je zbrala malo oziroma veliko točk.

Rows: 16,737

Columns: 19

```
$ `Loyalty Number`      <dbl> 100018, 100102, 100140, 100214, 100272, 10030~
$ Churn                 <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, ~
$ Gender                <chr> "Female", "Male", "Female", "Male", "Female", ~
$ Education             <chr> "Bachelor", "College", "College", "Bachelor", ~
$ Salary                <dbl> 92552, NA, NA, 63253, 91163, 70323, 76849, 69~
$ `Marital Status`     <chr> "Married", "Single", "Divorced", "Married", "~
$ `Loyalty Card`       <chr> "Aurora", "Nova", "Nova", "Star", "Star", "No~
$ `Enrollment Type`   <chr> "Standard", "Standard", "Standard", "Standard~
$ `Enrollment Year`   <dbl> 2016, 2013, 2016, 2015, 2014, 2013, 2015, 201~
$ CLV                  <dbl> 7919.20, 2887.74, 2838.07, 4170.57, 6622.05, ~
$ total_flights        <dbl> 46, 51, 47, 22, 37, 41, 33, 33, 35, 19, 42, 4~
$ total_distance       <dbl> 81190, 68918, 72856, 38236, 54997, 62849, 459~
$ total_points_accumulated <dbl> 81190, 68918, 72856, 38236, 54997, 62849, 459~
$ total_points_redeemed <dbl> 1513, 1195, 593, 861, 1007, 1381, 559, 1142, ~
$ total_dollar_redeemed <dbl> 272, 215, 107, 155, 182, 249, 101, 206, 298, ~
$ mean_monthly_flights <dbl> 1.9166667, 2.1250000, 1.9583333, 0.9166667, 1~
$ mean_monthly_distance <dbl> 3382.917, 2871.583, 3035.667, 1593.167, 2291.~
$ mean_monthly_points   <dbl> 3382.917, 2871.583, 3035.667, 1593.167, 2291.~
$ redemption_rate       <dbl> 0.018635300, 0.017339447, 0.008139343, 0.0225~
```

Loyalty Number	Churn	Gender	Education
Min. :100018	Min. :0.0000	Length:16737	Length:16737
1st Qu.:326603	1st Qu.:0.0000	Class :character	Class :character
Median :550434	Median :0.0000	Mode :character	Mode :character
Mean :549736	Mean :0.1235		
3rd Qu.:772019	3rd Qu.:0.0000		
Max. :999986	Max. :1.0000		

Salary	Marital Status	Loyalty Card	Enrollment Type
Min. : 15609	Length:16737	Length:16737	Length:16737
1st Qu.: 59265	Class :character	Class :character	Class :character
Median : 73510	Mode :character	Mode :character	Mode :character
Mean : 79430			
3rd Qu.: 88600			
Max. :407228			
NA's :4258			

```

Enrollment Year      CLV      total_flights      total_distance
Min.   :2012      Min.   : 1898      Min.   :  0.00      Min.   :    0
1st Qu.:2014      1st Qu.: 3981      1st Qu.: 19.00      1st Qu.: 27543
Median :2015      Median : 5780      Median : 33.00      Median : 49073
Mean   :2015      Mean   : 7989      Mean   : 29.95      Mean   : 44908
3rd Qu.:2017      3rd Qu.: 8941      3rd Qu.: 42.00      3rd Qu.: 62604
Max.   :2018      Max.   :83325      Max.   :104.00      Max.   :178858

total_points_accumulated total_points_redeemed total_dollar_redeemed
Min.   :    0      Min.   :  0.0      Min.   :  0.0
1st Qu.: 27900      1st Qu.:  0.0      1st Qu.:  0.0
Median : 49604      Median : 559.0      Median :101.0
Mean   : 46904      Mean   : 723.8      Mean   :130.3
3rd Qu.: 63430      3rd Qu.:1158.0      3rd Qu.:208.0
Max.   :268287      Max.   :4479.0      Max.   :806.0

mean_monthly_flights mean_monthly_distance mean_monthly_points
Min.   :0.0000      Min.   :  0      Min.   :  0
1st Qu.:0.7917      1st Qu.: 1164      1st Qu.: 1164
Median :1.4167      Median : 2072      Median : 2074
Mean   :1.3791      Mean   : 2068      Mean   : 2249
3rd Qu.:1.7500      3rd Qu.: 2659      3rd Qu.: 2664
Max.   :9.4545      Max.   :16260      Max.   :24390
NA's   :1      NA's   :1      NA's   :1

redemption_rate
Min.   :0.00000
1st Qu.:0.00000
Median :0.01165
Mean   :0.01601
3rd Qu.:0.02326
Max.   :1.19435

```

```

# A tibble: 2 x 3
  Churn    n percentage
  <dbl> <int>    <dbl>
1     0 14670     87.6
2     1  2067     12.4

```

V vzorcu je delež strank, ki so preklicale članstvo, približno 12 %, zato je ciljna spremenljivka neuravnotežena. To je pomembno pri vrednotenju modela, saj sama klasifikacijska točnost (accuracy) v takem primeru ni zadostna metrika. Model, ki bi vse stranke uvrstil med neodšle, bi namreč dosegel relativno visoko accuracy, vendar ne bi identificiral nobene stranke, ki bo program zapustila.

Pretvorimo kategorične spremenljivke v faktorje

```

$Gender
[1] "Female" "Male"

$Education
[1] "Bachelor"          "College"          "Doctor"
[4] "High School or Below" "Master"

$`Marital Status`
[1] "Divorced" "Married"  "Single"

```

```
$`Loyalty Card`
[1] "Aurora" "Nova" "Star"
```

```
$`Enrollment Type`
[1] "2018 Promotion" "Standard"
```

Pred modeliranjem smo preverili prisotnost manjkajočih vrednosti. Ker logistična regresija zahteva popolne vrednosti uporabljenih spremenljivk, smo iz analize izločili enote z manjkajočimi vrednostmi.

Podatke smo razdelili na 70 % učno in 30 % testno množico. Model je bil ocenjen izključno na učni množici, njegova napovedna uspešnost pa je bila nato preverjena na testni množici, ki pri ocenjevanju modela ni bila uporabljena. S tem zmanjšamo tveganje, da bi ocena uspešnosti temeljila na podatkih, na katerih je bil model naučen.

Call:

```
glm(formula = Churn ~ Gender + Education + Salary + `Marital Status` +
    `Loyalty Card` + `Enrollment Type` + `Enrollment Year` +
    CLV + total_flights + total_points_redeemed + redemption_rate,
    family = binomial, data = train_data)
```

Coefficients:

	Estimate	Std. Error	z value
(Intercept)	548.06163752458	40.91789079310	13.394
GenderMale	-0.02904547561	0.07944818007	-0.366
EducationDoctor	-0.10884892169	0.25460103881	-0.428
EducationHigh School or Below	-0.16231456457	0.17196934238	-0.944
EducationMaster	0.31559566450	0.20572065894	1.534
Salary	-0.00000006344	0.00000174036	-0.036
`Marital Status`Married	0.17324710731	0.10941914556	1.583
`Marital Status`Single	0.29800685783	0.13667317256	2.180
`Loyalty Card`Nova	0.02622586196	0.10984418483	0.239
`Loyalty Card`Star	-0.03397526685	0.10765450992	-0.316
`Enrollment Type`Standard	-2.10234455919	0.19454432126	-10.807
`Enrollment Year`	-0.27091474799	0.02026509046	-13.369
CLV	0.00000371069	0.00000566894	0.655
total_flights	-0.09218716343	0.00345176787	-26.707
total_points_redeemed	-0.00065937336	0.00011030107	-5.978
redemption_rate	0.67855006294	1.01903895621	0.666

	Pr(> z)
(Intercept)	< 0.0000000000000002 ***
GenderMale	0.7147
EducationDoctor	0.6690
EducationHigh School or Below	0.3452
EducationMaster	0.1250
Salary	0.9709
`Marital Status`Married	0.1133
`Marital Status`Single	0.0292 *
`Loyalty Card`Nova	0.8113
`Loyalty Card`Star	0.7523
`Enrollment Type`Standard	< 0.0000000000000002 ***
`Enrollment Year`	< 0.0000000000000002 ***
CLV	0.5127
total_flights	< 0.0000000000000002 ***
total_points_redeemed	0.00000000226 ***

```
redemption_rate          0.5055
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 6381.2  on 8733  degrees of freedom
Residual deviance: 4306.7  on 8718  degrees of freedom
AIC: 4338.7
```

Number of Fisher Scoring iterations: 6

	Predicted	
Actual	0	1
0	3158	89
1	273	224

	Accuracy	Sensitivity	Specificity	Precision	F1
	0.9033120	0.4507042	0.9725901	0.7156550	0.5530864

Na testnem vzorcu je logistični model dosegel 90,76 % točnost napovedi (accuracy). Vendar sama točnost v primeru napovedovanja churn-a ni zadostna za oceno uspešnosti modela, saj je delež strank, ki odpovejo članstvo, relativno majhen.

Model je dosegel zelo visoko specifičnost (97,43 %), kar pomeni, da zelo uspešno prepozna stranke, ki članstva ne bodo odpovedale. Po drugi strani je občutljivost (sensitivity) precej nižja in znaša 44,84 %. Model tako pravilno prepozna približno 45 % strank, ki dejansko odpovejo članstvo, medtem ko približno 55 % churniranih strank ne prepozna.

Precision znaša 71,72 %, kar pomeni, da je med strankami, ki jih model označi kot potencialno odhajajoče, približno 72 % dejansko takšnih, ki odpovejo članstvo. F1-vrednost 55,18 % kaže na zmerno ravnotežje med precision in sensitivity.

Rezultati kažejo, da je model precej uspešnejši pri prepoznavanju strank, ki bodo ostale v programu, kot pri identificiranju strank z dejanskim tveganjem za churn. Ker je namen modela podpora ukrepom za zadržanje strank, bi bilo zato smiselno preveriti tudi druge klasifikacijske pragove. Prag 0,5 je namreč lahko preveč strog, zaradi česar model spregleda precejšen delež potencialno odhajajočih strank.

9 Viri

1. članek/vir (osnove customer churn): Customer Churn Prediction: A Systematic Review of Recent Advances, Trends, and Challenges in Machine Learning and Deep Learning *Imani, M., Joudaki, M., Beikmohammadi, A., & Arabnia, H. R. (2025)* Link: [1.clanek] (www.mdpi.com/2504-4990/7/3/105?utm_source=chatgpt.com)
2. članek/vir: An asymmetrical approach to understanding configurations of customer loyalty in the airline industry *Catherine Prenticea, Sandra Maria Correia Loureirob* Link: [2.clanek] (https://www.sciencedirect.com/science/article/pii/S0969698917301789?fr=RR-1&ref=cra_js_challenge)
3. članek/vir: Key drivers of passenger loyalty: A case of Frankfurt–Istanbul flights. (2016). *Journal of Air Transport Management* Link: [3.clanek] (https://www.sciencedirect.com/science/article/pii/S0969699715300120?utm_source=chatgpt.com)
4. članek/vir: Frequent flyer programs in academic studies: A literature review of research progress since 2000. (2025). *Journal of Air Transport Management*. Link: [4.clanek] (https://www.sciencedirect.com/science/article/pii/S0969699725001838?utm_source=chatgpt.com)
5. članek/vir: In Pursuit of Enhanced Customer Retention Management: Review, Key Issues, and Future Directions *Ascarza, E., Neslin, S. A., Netzer, O., et al. (2018)* Link: [5.clanek] (https://business.columbia.edu/sites/default/files-efs/pubfiles/25780/ascarza_et_al_choice_symposium.pdf)
6. članek/vir: Beyond Accuracy: What Data Quality Means to Data Consumers. (2015) *Richard Y. Wang & Diane M. Strong* Link: [6.clanek] (<https://www.tandfonline.com/doi/abs/10.1080/07421222.1996.11518099>) -> Kakovost podatkov
7. članek/vir: Data Fusion. *ACM Computing Surveys*, 41(1), Article 1. *Bleiholder, J., & Naumann, F. (2008)* Link: [7.clanek] (<https://dl.acm.org/doi/abs/10.1145/1456650.1456651>) -> Strategija razreševanja konfliktov in utemeljitev, zakaj brez dodatnih kriterijev izbira ni upravičena.
8. članek/vir: Data Cleaning of Data Streams *Restat, V., Rodenhausen, N., Antonin, C., & Störl, U. (2025)*. Link: [8.clanek] (<https://arxiv.org/abs/2507.20839>)
9. članek/vir: Data Cleaning: Problems and Current Approaches *Rahm, E., & Do, H. H. (2000)*. Link: [9.clanek] (https://www.researchgate.net/publication/220282831_Data_Cleaning_Problems_and_Current_Approaches)
10. članek/vir (Manca): The Long-Term Impact of Loyalty Programs on Consumer Purchase Behavior and Loyalty. *Journal of Marketing* *Liu, Y. (2007)*. Link: [10.clanek] (https://www.researchgate.net/publication/237396598_The_Long-Term_Impact_of_Loyalty_Programs_on_Consumer_Purchase_Behavior_and_Loyalty)
11. članek/vir (Manca): Understanding the Effect of Customer Relationship Management Efforts on Customer Retention and Customer Share Development. *Journal of Marketing* *Verhoef, P. C. (2003)*. Link: [11.clanek] (https://www.researchgate.net/publication/242113836_Understanding_the_Effect_of_Customer_Relationship_Management_Efforts_on_Customer_Retention_and_Customer_Share_Development)
12. članek/vir (Manca): Loyalty Programmes: Current Knowledge and Research Directions. *International Journal of Management Reviews* *Dorotic, M., Bijmolt, T. H. A., & Verhoef, P. C. (2011)*. Link: [12.clanek] (https://www.researchgate.net/publication/229915137_Loyalty_Programmes_Current_Knowledge_and_Research_Directions)
13. članek/vir (Manca): Perceived benefits of loyalty programs: Scale development and implications for relational strategies. *Journal of Business Research* *Mimouni-Chaabane, A., & Volle, P. (2009)*. Link: [13.clanek] (<https://www.sciencedirect.com/science/article/abs/pii/S0148296309000198>)
14. članek/vir (Manca): Review of the theoretical underpinnings of loyalty programs. *Journal of Consumer Psychology* *Henderson, C. M., Beck, J. T., & Palmatier, R. W. (2011)*. Link: [14.clanek] (<https://www.sciencedirect.com/science/article/abs/pii/S1057260011000198>)

[//www.semanticscholar.org/paper/Review-of-the-theoretical-underpinnings-of-loyalty-Henderson-Beck/61ee71d3519da2034b51d2d03132916b2f351300](https://www.semanticscholar.org/paper/Review-of-the-theoretical-underpinnings-of-loyalty-Henderson-Beck/61ee71d3519da2034b51d2d03132916b2f351300))

15. članek/vir (Tristan): Power laws, Pareto distributions, and Zipf's law *Newman, M. E. J. (2004). Contemporary Physics, 46(5), 323–351.* Link: [15.clanek] (<https://arxiv.org/abs/cond-mat/0412004>)
16. članek/vir (Tristan): Customer Lifetime Value as the Basis of Customer Segmentation: Issues and Challenges *Katherine N. Lemon & Tanya Mark (2008). Journal of Relationship Marketing, 5(2–3), 55–69.* Link: [16.clanek] (https://doi.org/10.1300/J366v05n02_04)
17. članek/vir (Tristan): Benefits of quantile regression for the analysis of customer lifetime value in a contractual setting: An application in financial services *Benoit, D. F., & Van den Poel, D. (2009). Expert Systems with Applications, 36(7), 10475–10484.* Link: [17.clanek] (<https://doi.org/10.1016/j.eswa.2009.01.031>)
18. članek/vir (Tristan): Estimating travellers' value when purchasing auxiliary services in the airline industry based on the RFM model *Chen, Y., Liu, L., Zheng, D., & Li, B. (2023). Journal of Retailing and Consumer Services, 74, 103433.* Link: [18.clanek] (<https://www.sciencedirect.com/science/article/pii/S0969698923001807>)
19. članek/vir (Tristan): Breakage analysis for profitability management in high-value, low-frequency loyalty programs *Goić, M., Montoya, R., & Troncoso, I. (2025). International Journal of Research in Marketing, 42(2), 450–466.* Link: [19.clanek] (<https://www.sciencedirect.com/science/article/pii/S0167811624000909>)
20. članek/vir (Tristan): Tactical use of rewards to enhance loyalty program effectiveness *Danaher, P. J., Sajtos, L., & Danaher, T. S. (2020). International Journal of Research in Marketing, 37(3), 505–520.* Link: [20.clanek] (<https://doi.org/10.1016/j.ijresmar.2020.02.005>)