

Projekt - Airline Loyalty Program Promotion and Beyond

Manca Prošek, Tristan Dragan, Patricija Jaklič

2026-08-14

Eksploratorna podatkovna analiza

1. Customer Flight Activity.csv

```
kable(summary(Customer_Flight_Activity))
```


Loyalty Number	Year	Month	Total Flights	Distance	Points Accumulated	Points Re-deemed	Dollar Cost Points Redeemed
Min. :100018	Min. :2017	Min. : 1.000	Min. : 0.000	Min. : 0	Min. : 0	Min. : 0.0	Min. : 0.000
1st Qu.:327688	1st Qu.:2017	1st Qu.: 4.000	1st Qu.: 0.000	1st Qu.: 0	1st Qu.: 0	1st Qu.: 0.0	1st Qu.: 0.000
Median :551833	Median :2018	Median : 7.000	Median : 0.000	Median : 0	Median : 0	Median : 0.0	Median : 0.000
Mean :550528	Mean :2018	Mean : 6.514	Mean : 1.295	Mean : 1941	Mean : 2027	Mean : 31.3	Mean : 5.636
3rd Qu.:772194	3rd Qu.:2018	3rd Qu.:10.000	3rd Qu.: 2.000	3rd Qu.: 3018	3rd Qu.: 3039	3rd Qu.: 0.0	3rd Qu.: 0.000
Max. :999986	Max. :2018	Max. :12.000	Max. :28.000	Max. :67284	Max. :100926	Max. :876.0	Max. :158.000

```
anyNA.data.frame(Customer_Flight_Activity)
```

```
## [1] FALSE
```

Podatkovni okvir vsebuje mesečno aktivnost članov programa zvestobe (Customer Flight Activity). Vsebuje 392,936 vrstic in 8 stolpcev, pri čemer vsaka vrstica predstavlja en let. Vse spremenljivke so numerične. Vidimo lahko, da so vrednosti v večini smiselne (na primer nimamo negativnega števila vseh letov, ipd.). Podatki so bili zbrani med letoma 2017 in 2018, člani programa zvestobe pa so opravili med 0 in 28 letov. Že iz povzetka lahko razberemo, da so podatki asimetrično porazdeljeni. Razen spremenljivk **Loyalty Number** in **Year**, katerih porazdelitev ni smiselna za analizo ter **Month**, ki je skoraj uniformno porazdeljen. Ni manjkajočih vrednosti.

```
Customer_Flight_Activity %>%  
  select(-`Loyalty Number`) %>%  
  plot_histogram(ncol=3L)
```




Vizualizacija potrди naše sume glede močne (desne) asimetričnosti podatkov. Ta nam lahko v nadaljnjih analizah, kjer predpostavljamo normalnost, povzroča velike težave. Poskusimo jo odpraviti z logaritmiranjem.

```
# brez teh
exclude_cols <- c("Loyalty Number", "Month", "Year")

# numerični
cols_to_log <- Customer_Flight_Activity %>%
  select(where(is.numeric), -any_of(exclude_cols)) %>%
  names()

Customer_Flight_Activity_Log <- Customer_Flight_Activity %>%
  mutate(across(all_of(cols_to_log), ~ log(.x)))

Customer_Flight_Activity_Log %>%
  select(-`Loyalty Number`, -`Month`) %>%
  plot_histogram(ncol=3L)
```



Pri večini spremenljivk se z logaritmiranjem precej popravimo asimetričnost, v primeru **Points Redeemed** (vnovčene točke) se celo približamo normalni porazdelitvi, pri **Total Flights** (vsi leti) pa vsaj nekoliko zmanjšamo asimetričnost.

2. Customer Loyalty History.csv

```
# povzetek s knjižnjico skim
skimmed <- skim(Customer_Loyalty_History)


skimmed %>%
  select(skim_type, skim_variable, n_missing, complete_rate,
         numeric.mean, numeric.sd,
         character.n_unique, character.empty, character.min, character.max) %>%
  kable()
```

skim_type	skim_variable	n_missing	complete_rate	numeric.mean	numeric.sd	character.n_unique	character.empty	character.min	character.max
character	Country	0	1.0000000	NA	NA	1	0	6	6
character	Province	0	1.0000000	NA	NA	11	0	5	20
character	City	0	1.0000000	NA	NA	29	0	4	14
character	Postal Code	0	1.0000000	NA	NA	55	0	7	7
character	Gender	0	1.0000000	NA	NA	2	0	4	6
character	Education	0	1.0000000	NA	NA	5	0	6	20
character	Marital Status	0	1.0000000	NA	NA	3	0	6	8
character	Loyalty Card	0	1.0000000	NA	NA	3	0	4	6


skim_type	skim_variable	n_missing	complete_rate	numeric.mean	numeric.sd	character.n_unique	character.nchar	character.max
character	Enrollment Type	0	1.0000000	NA	NA	2	0	14
numeric	Loyalty Number	0	1.0000000	549735.880245	912.132453	NA	NA	NA
numeric	Salary	4238	0.7467886	79245.609439	9008.297285	NA	NA	NA
numeric	CLV	0	1.0000000	7988.896536	860.982280	NA	NA	NA
numeric	Enrollment Year	0	1.0000000	2015.253211	979111	NA	NA	NA
numeric	Enrollment Month	0	1.0000000	6.669116	3.398958	NA	NA	NA
numeric	Cancellation Year	14670	0.1234988	2016.503145	380743	NA	NA	NA
numeric	Cancellation Month	14670	0.1234988	6.962748	3.455297	NA	NA	NA

Podatkovni okvir vsebuje podatke o članih programa zvestobe (Customer Loyalty History). Vsebuje 16,737 vrstic in 16 stolpcev, pri čemer vsaka vrstica predstavlja posameznega člana iz Kanade. Numeričnih spremenljivk je 7, opisnih pa 9. Tako imamo podatke od izobrazbe in zakonskega stana pa vse do plače. Prav **Salary** (plača) in **CLV** (*Customer lifetime value - total invoice value for all flights ever booked by member* ali skupna vrednost kupca) delujeta asimetrično, dobro bi bilo da preverimo to še vizualno. Spremenljivke z manjkajočimi vrednostmi so: **Salary** (25.32%), **Cancellation Month** (87.65%) in **Cancellation Year** (87.65%). Pri prvi gre za prave manjkajoče vrednosti, pri zadnjih dveh pa vrednost NA pomeni, da član ni zapustil programa zvestobe, kot je to navedeno v pripadajočem gradivu *Airline Loyalty Program Promotion and Beyond_PS 2026*.

```
# numerične
Customer_Loyalty_History %>%
  select(-`Loyalty Number`) %>%
  plot_histogram()
```



```
# opisne
Customer_Loyalty_History %>%
  select(-`Country`) %>%
  mutate(
    across(
      where(is.character),
      # top 10
      ~ fct_lump_n(.x, n = 10, other_level = "Other")
    )
  ) %>%
  plot_bar()
```



Spremenljivka City ima 29 kategorij, Postal Code pa kar 55, zaradi lažje preglednosti na grafih je dodana še kategorija "Other". Salary in CLV sta močno (desno) asimetrična zato ju tako kot prejšnje spremenljivke logaritmiramo. Prav tako smo pri spremenljivki Salary smo zaznali negativne vrednosti. Pri plači pričakujemo samo pozitivne vrednosti zato bomo v nadaljevanju po principu čiščenja in ocenjevanja kakovosti podatkov obravnavali te vrednosti kot manjkajoče.


```
# negativne vrednosti v Salary z NA
Customer_Loyalty_History <- Customer_Loyalty_History %>%
  mutate(Salary = if_else(Salary < 0, NA_real_, Salary))

# izključi
exclude_cols <- c("Loyalty Number", "Postal Code", "Loyalty Card", "Enrollment Year",
  "Enrollment Month", "Cancellation Year", "Cancellation Month")

cols_to_log <- Customer_Loyalty_History %>%
  select(where(is.numeric), -any_of(exclude_cols)) %>%
  names()

# log
Customer_Loyalty_History_Log <- Customer_Loyalty_History %>%
  mutate(across(all_of(cols_to_log), ~ log(.x)))

Customer_Loyalty_History_Log %>%
  select(`CLV`, `Salary`) %>%
  plot_histogram(ncol=4L)
```



Z logaritmiranjem **Salary** in **CLV** smo delno odpravili močno asimetričnost, ki je bila prisotna prej.

Viri

Customer churn

1. članek/vir (osnove customer churn): Customer Churn Prediction: A Systematic Review of Recent Advances, Trends, and Challenges in Machine Learning and Deep Learning *Imani, M., Joudaki, M., Beikmohammadi, A., & Arabnia, H. R. (2025)* Link: [1.clanek] (www.mdpi.com/2504-4990/7/3/105?utm_source=chatgpt.com)
2. članek/vir: An asymmetrical approach to understanding configurations of customer loyalty in the airline industry *Catherine Prenticea, Sandra Maria Correia Loureirob* Link: [2.clanek] (https://www.sciencedirect.com/science/article/pii/S0969698917301789?fr=RR-1&ref=cra_js_challenge)
3. članek/vir: Key drivers of passenger loyalty: A case of Frankfurt–Istanbul flights. (2016). *Journal of Air Transport Management* Link: [3.clanek] (https://www.sciencedirect.com/science/article/pii/S096969715300120?utm_source=chatgpt.com)
4. članek/vir: Frequent flyer programs in academic studies: A literature review of research progress since 2000. (2025). *Journal of Air Transport Management*. Link: [4.clanek] (https://www.sciencedirect.com/science/article/pii/S0969699725001838?utm_source=chatgpt.com)
5. članek/vir: In Pursuit of Enhanced Customer Retention Management: Review, Key Issues, and Future Directions *Ascarza, E., Neslin, S. A., Netzer, O., et al. (2018)* Link: [5.clanek] (https://business.columbia.edu/sites/default/files-efs/pubfiles/25780/ascarza_et_al_choice_symposium.pdf)
6. članek/vir: Beyond Accuracy: What Data Quality Means to Data Consumers. (2015) *Richard Y. Wang & Diane M. Strong* Link: [6.clanek] (<https://www.tandfonline.com/doi/abs/10.1080/07421222.1996.11518099>) -> Kakovost podatkov

7. članek/vir: Data Fusion. ACM Computing Surveys, 41(1), Article 1. *Bleiholder, J., & Naumann, F. (2008)* Link: [7.clanek] (<https://dl.acm.org/doi/abs/10.1145/1456650.1456651>) -> Strategija razreševanja konfliktov in utemeljitev, zakaj brez dodatnih kriterijev izbira ni upravičena.
8. članek/vir: Data Cleaning of Data Streams *Restat, V., Rodenhausen, N., Antonin, C., & Störl, U. (2025)*. Link: [8.clanek] (<https://arxiv.org/abs/2507.20839>)
9. članek/vir: Data Cleaning: Problems and Current Approaches *Rahm, E., & Do, H. H. (2000)*. Link: [9.clanek] (https://www.researchgate.net/publication/220282831_Data_Cleaning_Problems_and_Current_Approaches)
10. članek/vir (Manca): The Long-Term Impact of Loyalty Programs on Consumer Purchase Behavior and Loyalty. Journal of Marketing *Liu, Y. (2007)*. Link: [10.clanek] (https://www.researchgate.net/publication/237396598_The_Long-Term_Impact_of_Loyalty_Programs_on_Consumer_Purchase_Behavior_and_Loyalty)
11. članek/vir (Manca): Understanding the Effect of Customer Relationship Management Efforts on Customer Retention and Customer Share Development. Journal of Marketing *Verhoef, P. C. (2003)*. Link: [11.clanek] (https://www.researchgate.net/publication/242113836_Understanding_the_Effect_of_Customer_Relationship_Management_Efforts_on_Customer_Retention_and_Customer_Share_Development)
12. članek/vir (Manca): Loyalty Programmes: Current Knowledge and Research Directions. International Journal of Management Reviews *Dorotic, M., Bijmolt, T. H. A., & Verhoef, P. C. (2011)*. Link: [12.clanek] (https://www.researchgate.net/publication/229915137_Loyalty_Programmes_Current_Knowledge_and_Research_Directions)
13. članek/vir (Manca): Perceived benefits of loyalty programs: Scale development and implications for relational strategies. Journal of Business Research *Mimouni-Chaabane, A., & Volle, P. (2009)*. Link: [13.clanek] (<https://www.sciencedirect.com/science/article/abs/pii/S0148296309000198>)
14. članek/vir (Manca): Review of the theoretical underpinnings of loyalty programs. Journal of Consumer Psychology *Henderson, C. M., Beck, J. T., & Palmatier, R. W. (2011)*. Link: [14.clanek] (<https://www.semanticscholar.org/paper/Review-of-the-theoretical-underpinnings-of-loyalty-Henderson-Beck/61ee71d3519da2034b51d2d03132916b2f351300>)

Ocena kakovosti podatkov

Magisterska naloga-Janez-Bijec

Vir/pomoč: Magistrska naloga: Janez Bijec: Statistični kazalniki kakovosti in učinkovitosti oskrbe pacientov s koronarno boleznijo

Izpiski: - Kdaj so podatki kakovostni? Kadar so "fit for purpose" - ocenjevanje kakovosti podatkov prilagodit vsaki analizi posebej glede na njene zahteve - Avtor v svoji analizi uporabi dva načina: - 1. Na podlagi modela ocenjevanja in terminologije dimenzij kakovosti (prilagojen za elektronske zdravstvene podatke) (*skladnost, celovitost, prepričljivost - verjetnost*) - 2. konceptualni način

1.NAČIN

MODEL OCENJEVANJA IN TERMINOLOGIJE DIMENZIJ KAKOVOSTI

- a. SKLADNOST - ali so podatki skladni z definiranimi formati, ustrezajo pričakovani obliki in opisom v metapodatkih (poddimenzije: vrednostna skladnost, relacijska skladnost, računska skladnost)
 - VREDNOSTNA skladnost: spol ima samo dve vrednosti, starost nima negativnih vrednosti,...
 - RELACIJSKA skladnost: omogočanje relacije med tabelami v bazi podatkov
 - RAČUNSKA pravilnost izpeljanih spremenljivk

- b. CELOVITOST - dimenzija kakovosti, ki ocenjuje prisotnost oz. odsotnost (tudi frekvenco podatkov) ne da bi se ozirala na vrednosti, ki jih podatki zavzemajo. Ta dimenzija kakovosti nima poddimenzij.
- c. PREPRIČLJIVOST - VERJETNOST: dimenzija kakovosti, ki osredotoča na same vrednosti, ki jih zavzemajo (imajo podatki) in poskuša odgovoriti na vprašanje, kako vrednosti podatkov opisujejo realno stanje, koliko jim je mogoče zaupati.

Poddimenzijske: - UNIKATNA PREPRIČLJIVOST (angl. Uniqueness plausibility) podvajanje podatkov, tam kjer niso smiselni (npr. en identifikator pacienta je povezan z dvema spoloma ali dvema različnima glavnima diagnozama za isto hospitalizacijo) - NEČASOVNA PREPRIČLJIVOST (angl. Atemporal plausibility) Povezana z oceno koliko se vrednosti in porazdelitve vrednosti skladajo glede na neko splošno vedenje ali glede na nek zunanji standard. (npr. telesne višine pacientov se porazdeljuje normalno s povprečjem 170 cm in standardnim odklonom 15cm) - ČASOVNA PREPRIČLJIVOST (angl. Temporal plausibility) Smiselnost in pravilnost spreminjanja ali ohranjanja vrednosti spremenljivk glede na čas (npr. ali je telesna višina pri večini pacientov v adolescenci smiselno naraščala, odraslega pacienta pa ostala nespremenljiva)

Ocenjevanje dimenzij kakovosti

1. VERTIFIKACIJA (angl. Verification)

Temelji na podatkih kot takih na smiselnosti na ujemanju z omejitvami in strukturo na ekspertnih mnenjih in logičnih povezavah.

2. VALIDACIJA (angl. Validation)

Temelji na preverjanju podatkov glede na nek zunanji vir, ki lahko predstavlja zlati standard.

2. NAČIN-KONCEPTUALNI

Avtor poskuša odkriti določene sistemske pomanjklivosti v podatkih. Ideja Weng in Casey -> predpostavka merljivih konceptov v medicini

OCENA-KAKOVOSTI-PODATKOV

Kakovost podatkov bomo preverili na podlagi šestih najbolj uporabljenih dimenzij od petnajstih, ki so navedeni v (6.članku). Odločili smo se za šest dimenzij na podlagi literature in praks.

Glavne dimenzije ocenjevanja kvalitete podatkov, ki jih bomo upoštevali pri naši analizi so:

1. Natančnost ali točnost
2. Celovitost
3. Doslednost
4. Pravočasnost
5. Veljavnost
6. Enoličnost

1. Natančnost podatkov

Natančnost podatkov pomeni, kako dobro se informacije ujemajo z dejstvi iz resničnega sveta. Natančnost podatkov se osredotoča na pravilnost in zanesljivost podatkov ter zagotavlja, da ti ne vsebujejo napak, ki bi nastale zaradi nepravilnega vnosa ali pomanjkljive obdelave. Primarni cilj zagotavljanja točnosti podatkov je prepoznavanje in odpravljanje napak v podatkovnih vrednostih, kot so napake pri prepisovanju, podvojeni vnosi in napačne vrednosti. Točnost podatkov se dosega z uporabo:

- čiščenja podatkov za prepoznavanje in odpravljanje napak ter neskladnosti v naborih podatkov, kot so odstranjevanje podvojenih zapisov, popravljanje tipkarskih napak in standardizacija podatkov

– preverjanja veljavnosti podatkov s pomočjo vnaprej določenih pravil ali algoritmov za odkrivanje napak, neskladnosti in netočnosti v podatkih med postopkom vnosa ali naknadno

– profiliranja podatkov za prepoznavanje vzorcev, trendov in nepravilnosti v naborih podatkov, ki lahko kažejo na netočnosti ali neskladnosti.

Za naše podatke nimamo zunanjih referenčnih virov s katerim bi lahko naredili neposredno primerjavo podatkov za preverjanje točnosti podatkov, ker nimamo neodvisnega vira točnosti podatkov ne moremo empirično dokazati. Zato bomo v nadaljevanju preverjali logična pravila in potencialne napačne oz. ekstremne vrednosti.

```
summary(Customer_Flight_Activity)
```

```
## Loyalty Number      Year      Month      Total Flights
## Min.   :100018      Min.   :2017      Min.   : 1.000      Min.   : 0.000
## 1st Qu.:327688      1st Qu.:2017      1st Qu.: 4.000      1st Qu.: 0.000
## Median :551833      Median :2018      Median : 7.000      Median : 0.000
## Mean   :550528      Mean   :2018      Mean   : 6.514      Mean   : 1.295
## 3rd Qu.:772194      3rd Qu.:2018      3rd Qu.:10.000      3rd Qu.: 2.000
## Max.   :999986      Max.   :2018      Max.   :12.000      Max.   :28.000
##      Distance      Points Accumulated Points Redeemed Dollar Cost Points Redeemed
## Min.   : 0      Min.   : 0      Min.   : 0.0      Min.   : 0.000
## 1st Qu.: 0      1st Qu.: 0      1st Qu.: 0.0      1st Qu.: 0.000
## Median : 0      Median : 0      Median : 0.0      Median : 0.000
## Mean   : 1941      Mean   : 2027      Mean   : 31.3      Mean   : 5.636
## 3rd Qu.: 3018      3rd Qu.: 3039      3rd Qu.: 0.0      3rd Qu.: 0.000
## Max.   :67284      Max.   :100926      Max.   :876.0      Max.   :158.000
```

```
summary(Customer_Loyalty_History)
```

```
## Loyalty Number      Country      Province      City
## Min.   :100018      Length:16737      Length:16737      Length:16737
## 1st Qu.:326603      Class :character      Class :character      Class :character
## Median :550434      Mode  :character      Mode  :character      Mode  :character
## Mean   :549736
## 3rd Qu.:772019
## Max.   :999986
##
## Postal Code      Gender      Education      Salary
## Length:16737      Length:16737      Length:16737      Min.   : 15609
## Class :character      Class :character      Class :character      1st Qu.: 59265
## Mode  :character      Mode  :character      Mode  :character      Median : 73510
##                                     Mean   : 79430
##                                     3rd Qu.: 88600
##                                     Max.   :407228
##                                     NA's   :4258
## Marital Status      Loyalty Card      CLV      Enrollment Type
## Length:16737      Length:16737      Min.   : 1898      Length:16737
## Class :character      Class :character      1st Qu.: 3981      Class :character
## Mode  :character      Mode  :character      Median : 5780      Mode  :character
##                                     Mean   : 7989
##                                     3rd Qu.: 8941
##                                     Max.   :83325
##
## Enrollment Year      Enrollment Month      Cancellation Year      Cancellation Month
```

```
## Min. :2012 Min. : 1.000 Min. :2013 Min. : 1.000
## 1st Qu.:2014 1st Qu.: 4.000 1st Qu.:2016 1st Qu.: 4.000
## Median :2015 Median : 7.000 Median :2017 Median : 7.000
## Mean :2015 Mean : 6.669 Mean :2017 Mean : 6.963
## 3rd Qu.:2017 3rd Qu.:10.000 3rd Qu.:2018 3rd Qu.:10.000
## Max. :2018 Max. :12.000 Max. :2018 Max. :12.000
## NA's :14670 NA's :14670
```

2.Celovitost

Podatki so celoviti, če so prisotni vsi potrebni podatki ali so določene vrednosti manjkajoče. Celovitost ne pomeni le odsotnosti praznih polj, temveč tudi, ali zbrani podatki zadostno pokrivajo vse pomembne vidike analiziranega pojava.

```
map_dbl(Customer_Flight_Activity, ~mean(is.na(.))) %>% sort(decreasing = TRUE)
```

```
## Loyalty Number Year
## 0 0
## Month Total Flights
## 0 0
## Distance Points Accumulated
## 0 0
## Points Redeemed Dollar Cost Points Redeemed
## 0 0
```

```
map_dbl(Customer_Loyalty_History, ~mean(is.na(.))) %>% sort(decreasing = TRUE)
```

```
## Cancellation Year Cancellation Month Salary Loyalty Number
## 0.8765012 0.8765012 0.2544064 0.0000000
## Country Province City Postal Code
## 0.0000000 0.0000000 0.0000000 0.0000000
## Gender Education Marital Status Loyalty Card
## 0.0000000 0.0000000 0.0000000 0.0000000
## CLV Enrollment Type Enrollment Year Enrollment Month
## 0.0000000 0.0000000 0.0000000 0.0000000
```

V izpisanih tabelah lahko vidimo, da podatki o letih nimajo manjkajočih vrednosti, prav tako bi iz podakih podatkov rekli, da so podane vse potrebne vrednosti.

V tabeli podatkov o članih programa pa opazimo, da imamo manjkajoče vrednosti pri spremenljivki 'Salary' in pa seveda pri spremenljivkama 'Cancellation Year' in 'Cancellation Month', ki pa niso manjkajoči podatki, saj so to še aktualni člani in podatka enostavno ni. Tudi pri tem naboru podatkov bi za dane stolpce rekli, da so podatki dovolj obsežni in nam podajajo dovolj informacij za celovitost.

Vrnimo se sedaj k spremenljivki o plačah, kjer nam manjka 25% vrednosti. Trend manjkajočnosti si tu želimo bolj natančno pogledati, če uspemo najti kakšen vzorec.

```
# Vzorec manjkajočih vrednosti
Customer_Loyalty_History %>%
  filter(is.na(Salary)) %>%
  count(Gender)
```

```
## # A tibble: 2 x 2
## Gender n
## <chr> <int>
## 1 Female 2094
## 2 Male 2164
```

```
Customer_Loyalty_History %>%
  filter(is.na(Salary)) %>%
  count(`Loyalty Card`)
```

```
## # A tibble: 3 x 2
##   `Loyalty Card`      n
##   <chr>            <int>
## 1 Aurora             797
## 2 Nova              1341
## 3 Star              2120
```

```
Customer_Loyalty_History %>%
  filter(is.na(Salary)) %>%
  count(`Marital Status`)
```

```
## # A tibble: 3 x 2
##   `Marital Status`      n
##   <chr>            <int>
## 1 Divorced           378
## 2 Married           1451
## 3 Single            2429
```

Plače manjkajo vsem, ki imajo izobrazbo "College" !!!

```
Customer_Loyalty_History %>%
  filter(is.na(Salary)) %>%
  count(Education)
```

```
## # A tibble: 3 x 2
##   Education            n
##   <chr>            <int>
## 1 Bachelor           19
## 2 College          4238
## 3 High School or Below 1
```

```
Customer_Loyalty_History %>%
  count(Education)
```

```
## # A tibble: 5 x 2
##   Education            n
##   <chr>            <int>
## 1 Bachelor        10475
## 2 College         4238
## 3 Doctor           734
## 4 High School or Below 782
## 5 Master           508
```

Našli smo vzorec manjkajočnosti, in sicer podatek o plači je manjkajoč pri vseh, ki imajo nivo izobrazbe enak "College".

3. Doslednost

Doslednost podatkov pa predstavlja njihovo ujemanje med različnimi viri, sistemi ali časovnimi obdobji. Podatki so dosledni, kadar ni protislovij in kadar so medsebojno logično skladni.

Ali imajo vsi poleti veljavno stranko v loyalty tabeli?

```
anti_join(Customer_Flight_Activity, Customer_Loyalty_History, by = "Loyalty Number") %>% nrow()
```

```
## [1] 0
```

```
# nesmiselne vrednosti
summary(Customer_Flight_Activity$`Total Flights`)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.000  0.000   0.000   1.295   2.000   28.000

summary(Customer_Flight_Activity$Distance)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##         0         0         0   1941   3018   67284

Customer_Flight_Activity %>% filter(`Total Flights` == 0 & Distance > 0)

## # A tibble: 0 x 8
## # i 8 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>,
## #   Total Flights <dbl>, Distance <dbl>, Points Accumulated <dbl>,
## #   Points Redeemed <dbl>, Dollar Cost Points Redeemed <dbl>

Customer_Flight_Activity %>% filter(`Total Flights` > 0 & Distance == 0)

## # A tibble: 0 x 8
## # i 8 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>,
## #   Total Flights <dbl>, Distance <dbl>, Points Accumulated <dbl>,
## #   Points Redeemed <dbl>, Dollar Cost Points Redeemed <dbl>

summary(Customer_Loyalty_History$Salary)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
##    15609  59265   73510   79430   88600  407228    4258

Customer_Loyalty_History %>% filter(Salary < 0)

## # A tibble: 0 x 16
## # i 16 variables: Loyalty Number <dbl>, Country <chr>, Province <chr>,
## #   City <chr>, Postal Code <chr>, Gender <chr>, Education <chr>, Salary <dbl>,
## #   Marital Status <chr>, Loyalty Card <chr>, CLV <dbl>, Enrollment Type <chr>,
## #   Enrollment Year <dbl>, Enrollment Month <dbl>, Cancellation Year <dbl>,
## #   Cancellation Month <dbl>
```

Pogledali smo še, če imajo vsi podatki o letih veljavno številko kartice zvestove v podatkih o kartičarjih in pa če obstajajo, kakšne nesmiselne vrednosti. Opazili smo negativne plače, ki jih bomo obravnavali pod točko 5, razen tega pa podatki delujejo dosledni.

4. Pravočasnost

Pravočasnost nam pove, ali so podatki na voljo dovolj hitro glede na potrebe uporabe in ali odražajo trenutno stanje. Pri analizi odtoka strank to pomeni, da podatki o vedenju strank ne smejo biti zastareli, saj se preference in vedenje hitro spreminjajo.

Ker analiziramo bazo starih podatkov in imamo pomanjkljive informacije o pridobitvi podatkov in prav tako o pridobivanju, bomo to točko spustili. Omenili smo jo, ker je izredno pomembna pri vseh analizah kakovosti podatkov in je ne smemo pozabiti. Za potrebe naše naloge bomo rekli, da so podatki pravočasni in da dobro odražajo trenutno stanje.


5. Veljavnost

Kot je bilo že ugotovljeno zgoraj smo opazili negativne vrednosti pri spremenljivki 'Salary', kar ni pričakovano. Te vrednosti smo zaznali kot neveljavne. V nadaljevanju bomo preverili ali obstaja kakšen vzorec negativnih vrednosti in se na podlagi podrobnejšega pregleda podatkov odločili kaj bomo z njimi naredili.

```
ggplot(Customer_Loyalty_History, aes(x = Salary)) +
  geom_histogram(binwidth=10000) +
  theme(panel.grid = element_blank()) +
  labs(
    title = "Porazdelitev spremenljivke Salary",
    x = "Salary",
    y = NULL
  )
```

```
## Warning: Removed 4258 rows containing non-finite outside the scale range
## (`stat_bin()`).
```

Porazdelitev spremenljivke Salary



```
Customer_Loyalty_History %>%
  filter(Salary < 0) %>%
  summarise(
    n = n(),
    min_salary = min(Salary),
    max_salary = max(Salary)
  )
```

```
## Warning: There were 2 warnings in `summarise()`.
## The first warning was:
## i In argument: `min_salary = min(Salary)`.
## Caused by warning in `min()`:
## ! no non-missing arguments to min; returning Inf
## i Run `dplyr::last_dplyr_warnings()` to see the 1 remaining warning.
## # A tibble: 1 x 3
```

```
##      n min_salary max_salary
##   <int>      <dbl>      <dbl>
## 1      0         Inf       -Inf

# delež
mean(Customer_Loyalty_History$Salary < 0, na.rm = TRUE)

## [1] 0

# Vzorec negativnih vrednosti
Customer_Loyalty_History %>%
  filter(Salary < 0) %>%
  count(Gender)

## # A tibble: 0 x 2
## # i 2 variables: Gender <chr>, n <int>

Customer_Loyalty_History %>%
  filter(Salary < 0) %>%
  count(Education)

## # A tibble: 0 x 2
## # i 2 variables: Education <chr>, n <int>

Customer_Loyalty_History %>%
  filter(Salary < 0) %>%
  count(`Loyalty Card`)

## # A tibble: 0 x 2
## # i 2 variables: Loyalty Card <chr>, n <int>

Customer_Loyalty_History %>%
  filter(Salary < 0) %>%
  summary()

## Loyalty Number   Country      Province      City
## Min.   : NA      Length:0      Length:0      Length:0
## 1st Qu.: NA      Class :character Class :character Class :character
## Median : NA      Mode  :character Mode  :character Mode  :character
## Mean   :NaN
## 3rd Qu.: NA
## Max.   : NA
## Postal Code      Gender      Education      Salary
## Length:0         Length:0      Length:0      Min.   : NA
## Class :character Class :character Class :character 1st Qu.: NA
## Mode  :character Mode  :character Mode  :character Median : NA
##                                     Mean   :NaN
##                                     3rd Qu.: NA
##                                     Max.   : NA
## Marital Status   Loyalty Card      CLV      Enrollment Type
## Length:0         Length:0      Min.   : NA      Length:0
## Class :character Class :character 1st Qu.: NA      Class :character
## Mode  :character Mode  :character Median : NA      Mode  :character
##                                     Mean   :NaN
##                                     3rd Qu.: NA
##                                     Max.   : NA
## Enrollment Year  Enrollment Month  Cancellation Year  Cancellation Month
## Min.   : NA      Min.   : NA      Min.   : NA      Min.   : NA
```

```
## 1st Qu.: NA      1st Qu.: NA      1st Qu.: NA      1st Qu.: NA
## Median : NA      Median : NA      Median : NA      Median : NA
## Mean   :NaN      Mean   :NaN      Mean   :NaN      Mean   :NaN
## 3rd Qu.: NA      3rd Qu.: NA      3rd Qu.: NA      3rd Qu.: NA
## Max.   : NA      Max.   : NA      Max.   : NA      Max.   : NA
```

```
# Opcija
Customer_Loyalty_History <- Customer_Loyalty_History %>%
  mutate(
    Salary = if_else(Salary < 0, NA_real_, Salary)
  )
```

6. Enoličnost

Enoličnost podatkov pomeni odsotnost podvojenih zapisov. To pomeni, da mora biti vsaka entiteta v podatkovni bazi zastopana samo enkrat. Enoličnost je pomembna za pravilno združevanje in preprečevanje dvojnega štetja pri analizah.

```
# Dvojniki po ključu
Customer_Loyalty_History %>% count(`Loyalty Number`) %>% filter(n > 1) # naj bo prazno - 1 vrstica na s
```

```
## # A tibble: 0 x 2
## # i 2 variables: Loyalty Number <dbl>, n <int>
```

```
Customer_Flight_Activity %>% count(`Loyalty Number`, Year, Month) %>% filter(n > 1) # naj bo prazno
```

```
## # A tibble: 3,847 x 4
##   `Loyalty Number` Year Month    n
##           <dbl> <dbl> <dbl> <int>
## 1           101902 2017     1     2
## 2           101902 2017     2     2
## 3           101902 2017     3     2
## 4           101902 2017     4     2
## 5           101902 2017     5     2
## 6           101902 2017     6     2
## 7           101902 2017     7     2
## 8           101902 2017     8     2
## 9           101902 2017     9     2
## 10          101902 2017    10     2
## # i 3,837 more rows
```

V zgornjem izpisu vidimo, da dvojnih vnosov o strankah ni, je pa kar veliko dvojnih vnosov v tabeli z leti. Če pogledamo dvojne vnose bolj natančno, opazimo, da imamo dve vrsti. Imamo dvojne vnose, ki so popolni dvojniki in imamo vnose, kjer so številka kartice zvestobe, leto in mesec enaki, ostali podatki pa so si med seboj različni. To sta dva problema, ki ju bomo obravnavali ločeno.

```
## Podvojene vrstice v Customer_Flight_Activity
key_cols <- c("Loyalty Number", "Year", "Month")

# Za vsako skupino preveri velikost skupine in št. dejansko različnih vrstic znotraj nje
key_dup_summary <- Customer_Flight_Activity %>%
  group_by(across(all_of(key_cols))) %>%
  summarise(
    group_size      = n(),
    n_distinct_rows = n_distinct(pick(everything())),
    .groups = "drop"
  ) %>%
```



```

filter(group_size > 1)

# Ključni, kjer je skupina POPOLN dvojničnik
full_dup_keys <- key_dup_summary %>%
  filter(n_distinct_rows == 1) %>%
  select(all_of(key_cols))

# Ključni, kjer skupina NI popoln dvojničnik
partial_dup_keys <- key_dup_summary %>%
  filter(n_distinct_rows > 1) %>%
  select(all_of(key_cols))

nrow(full_dup_keys)

## [1] 1904

nrow(partial_dup_keys)

## [1] 1943

# Vpogled v primer nepopolnih dvojničnikov
Customer_Flight_Activity %>%
  semi_join(partial_dup_keys, by = key_cols) %>%
  arrange(`Loyalty Number`, Year, Month) %>%
  head(10)

```

```

## # A tibble: 10 x 8
##   `Loyalty Number` Year Month `Total Flights` Distance `Points Accumulated`
##   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 101902 2017 4 1 667 667
## 2 101902 2017 4 1 2499 2499
## 3 101902 2017 5 3 7263 7263
## 4 101902 2017 5 2 3762 3762
## 5 101902 2017 6 3 4971 4971
## 6 101902 2017 6 3 5763 5763
## 7 101902 2017 8 5 3825 3825
## 8 101902 2017 8 4 8952 8952
## 9 101902 2017 9 2 3734 3734
## 10 101902 2017 9 1 2187 2187
## # i 2 more variables: `Points Redeemed` <dbl>,
## # `Dollar Cost Points Redeemed` <dbl>

```

- Obravnava popolnih dvojničnikov - literatura

V viru 9 (Rahm in Do, 2000, Data Cleaning: Problems and Current Approaches) avtorja navajata, da odprava dvojničnikov poteka v dveh korakih. Najprej identifikacija, ki smo jo že naredili, nato pa združitev oziroma odstranitev podvojenih zapisov. Ker imamo v našem primeru opravka s popolnimi dvojniki, kjer se vse vrednosti atributov ujemajo, med njimi ni nobenih protislovij ali manjkajočih informacij, ki bi jih bilo treba uskladiti. Zato lahko brez izgube podatkovne vsebine eno od kopij enostavno odstranimo, s čimer preprečimo dvojno štetje strank v nadaljnjih analizah, hkrati pa ohranimo celovitost in konsistentnost podatkovne baze.

- Obravnava nepopolnih dvojničnikov - literatura

V viru 7 (Bleiholder & Naumann, 2008, ACM Computing Surveys, "Data Fusion"), ki govori o usklajevanju nasprotujočih si vrednosti, obstaja uveljavljena klasifikacija strategij, ki ločuje tri pristope:

- Conflict-resolving (razreševanje konflikta), kjer si izbereš eno vrednost na podlagi nekega kriterija: zanesljivosti vira, časovne novosti zapisa, večinskega glasovanja med več viri, ali domenskega znanja.
- Conflict-avoiding (izogibanje), kjer uporabiš pravilo (npr. vedno vzemi maksimum, minimum, povprečje).
- Conflict-ignoring (nerazreševanje), kjer se konflikta sploh ne poskuša razrešiti, temveč se pusti nerazrešen ali označi kot neznan.

Prvi dve zgornji strategiji razreševanja potrebujeta vsaj neko dodatno informacijo, na podlagi katere bi se odločili, katera vrednost je pravilnejša. To bi bil lahko podatek o viru, časovni žig vnosa podatkov, nek drug dodatek vir in podobno. Ker pa mi poleg podatkov nimamo drugega in so si nekatere naše vrednosti nasprotujoče (število letov in prepotovana razdalja v teh primerih nista pozitivno povezana), bi bila izbira ene od privih dveh rešitev zgolj ugibanje. To tudi Rahm & Do (2000) in Restat et al. (2025) izpostavita kot problem, da brez dodatnih pravil ali človeške presoje se kontradiktornega zapisa ne da zanesljivo razrešiti.

Zato je tudi v literaturi v takšnih primerih priznana pot nerazreševanja, saj namesto, da se izmislimo, katera vrednost je prava, oba zapisa označimo kot manjkajoč podatek. S tem ne vnašamo umetne pristranskosti v podatke, ohranjamo transparentnos in če bi bilo takih podatkov veliko, jih lahko obravnavamo kot manjkajoče vrednosti. Je pa pomembno dodati, da je delež nepopolnih dvojnikov majhen in ne vpliva na rezultate naših nadaljnjih analiz.

Kljub temu podatke sčistimo kot smo se s pomočjo literature odločili.

```
# Nepopolni dvojniki = odstranimo vse
# Popolni dvojniki = odstranimo odvečne kopije

Customer_Flight_Activity_Clean <- Customer_Flight_Activity %>%
  anti_join(partial_dup_keys, by = key_cols) %>%
  distinct()

# Poročilo o čiščenju
n_total <- nrow(Customer_Flight_Activity)
n_removed_partial <- Customer_Flight_Activity %>% semi_join(partial_dup_keys, by = key_cols) %>% nrow()
n_removed_full_dup <- n_total - n_removed_partial - nrow(Customer_Flight_Activity_Clean)

cat("Vrstic prej:", n_total, "\n")

## Vrstic prej: 392936
cat("Odstranjenih (nepopolni dvojniki - vse vrstice skupine):", n_removed_partial, "\n")

## Odstranjenih (nepopolni dvojniki - vse vrstice skupine): 3894
cat("Odstranjenih (odvečne kopije popolnih dvojnikov):", n_removed_full_dup, "\n")

## Odstranjenih (odvečne kopije popolnih dvojnikov): 1920
cat("Vrstic po čiščenju:", nrow(Customer_Flight_Activity_Clean), "\n")

## Vrstic po čiščenju: 387122

# Kontrola = noben ključ naj se več ne podvaja
Customer_Flight_Activity_Clean %>% count(across(all_of(key_cols))) %>% filter(n > 1)

## # A tibble: 0 x 4
## # i 4 variables: Loyalty Number <dbl>, Year <dbl>, Month <dbl>, n <int>
```

Agregacija - Manca (če bi se slučajno rabili)

```
## 3.2 Agregacija po stranki (na podlagi Customer_Flight_Activity_Clean)
## -----

Customer_Activity <- Customer_Flight_Activity_Clean %>%
  group_by(`Loyalty Number`) %>%
  summarise(
    total_flights_sum = sum(`Total Flights`, na.rm = TRUE),
    total_distance = sum(Distance, na.rm = TRUE),
    points_accumulated = sum(`Points Accumulated`, na.rm = TRUE),
    points_redeemed = sum(`Points Redeemed`, na.rm = TRUE),
    dollar_cost_redeemed = sum(`Dollar Cost Points Redeemed`, na.rm = TRUE),
    active_months = n_distinct(paste(Year, Month)),
    .groups = "drop"
  ) %>%
  mutate(
    redemption_rate = if_else(points_accumulated > 0,
                               points_redeemed / points_accumulated, 0),
    avg_flights_per_month = total_flights_sum / active_months
  )

df <- Customer_Loyalty_History %>%
  left_join(Customer_Activity, by = "Loyalty Number") %>%
  mutate(
    is_promo_2018 = `Enrollment Type` == "2018 Promotion",
    churned = !is.na(`Cancellation Year`)
  )

glimpse(df)

## Rows: 16,737
## Columns: 26
## $ `Loyalty Number`      <dbl> 480934, 549612, 429460, 608370, 530508, 193662, ~
## $ Country               <chr> "Canada", "Canada", "Canada", "Canada", "Canada"~
## $ Province             <chr> "Ontario", "Alberta", "British Columbia", "Ontar~
## $ City                  <chr> "Toronto", "Edmonton", "Vancouver", "Toronto", "~
## $ `Postal Code`        <chr> "M2Z 4K1", "T3G 6Y6", "V6E 3D9", "P1W 1K4", "J8Y~
## $ Gender                <chr> "Female", "Male", "Male", "Male", "Male", "Male"~
## $ Education             <chr> "Bachelor", "College", "College", "College", "Ba~
## $ Salary                <dbl> 83236, NA, NA, NA, 103495, 51124, NA, 100159, 10~
## $ `Marital Status`     <chr> "Married", "Divorced", "Single", "Single", "Marr~
## $ `Loyalty Card`       <chr> "Star", "Star", "Star", "Star", "Star", "Star", ~
## $ CLV                   <dbl> 3839.14, 3839.61, 3839.75, 3839.75, 3842.79, 384~
## $ `Enrollment Type`   <chr> "Standard", "Standard", "Standard", "Standard", ~
## $ `Enrollment Year`   <dbl> 2016, 2016, 2014, 2013, 2014, 2012, 2014, 2016, ~
## $ `Enrollment Month`  <dbl> 2, 3, 7, 2, 10, 5, 6, 12, 5, 10, 3, 6, 1, 10, 11~
## $ `Cancellation Year`  <dbl> NA, NA, 2018, NA, NA, NA, NA, NA, NA, NA, NA, NA~
## $ `Cancellation Month` <dbl> NA, NA, 1, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
## $ total_flights_sum   <dbl> 37, 58, 18, 35, 37, 0, 40, 41, 27, 44, 51, 31, 2~
## $ total_distance      <dbl> 54525, 77487, 24803, 48432, 55515, 0, 61007, 728~
## $ points_accumulated  <dbl> 54525, 77487, 24803, 48432, 55515, 0, 61007, 728~
## $ points_redeemed     <dbl> 1418, 1971, 374, 1291, 0, 0, 1583, 733, 1516, 16~
## $ dollar_cost_redeemed <dbl> 256, 356, 67, 233, 0, 0, 285, 132, 274, 303, 90,~
```

```
## $ active_months      <int> 24, 24, 24, 24, 24, 4, 24, 24, 24, 24, 24, 24, 2~
## $ redemption_rate    <dbl> 0.026006419, 0.025436525, 0.015078821, 0.0266559~
## $ avg_flights_per_month <dbl> 1.5416667, 2.4166667, 0.7500000, 1.4583333, 1.54~
## $ is_promo_2018      <lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, ~
## $ churned            <lgl> FALSE, FALSE, TRUE, FALSE, FALSE, FALSE, FALSE, ~
```

Vizualizacija

(Manca) Razumeti dejavnike, ki vplivajo na vključenost v program zvestobe, in analizirati učinkovitost promocijske kampanje

1. Dejavniki angažiranja: večdimenzionalne koristi in heterogenost uporabnikov

Angažiranje v programih zvestobe poganja več vrst koristi, od denarne prihranke, raziskovanja, zabave do prepoznave in socialne koristi (Mimouni-Chaabane & Volle, 2009). Denarni prihranki so sicer najpomembnejši motivator za vključitev, vendar hedonske in simbolne koristi postanejo ključne za dolgoročno ohranjanje odnosa (Dorotic, Bijmolt & Verhoef, 2011). Še pomembneje je, da se odziv na program bistveno razlikuje glede na začetno raven porabe, saj težki kupci ne spreminjajo vedenja, medtem ko lahki in zmerni kupci postopoma povečujejo pogostost nakupov in zvestobo (Liu, 2007). Ta heterogenost je ključna za načrtovanje kampanj, ker enaka spodbuda ne bo enako učinkovita pri vseh segmentih. Verhoef (2003) dodaja, da čustvena zavezanost deluje kot posrednik med zaznanimi koristmi in dejanskim vedenjem, zato promocijske kampanje ne smejo ciljati le na kratkoročne ekonomske spodbude, temveč morajo graditi tudi čustveno povezanost.

2. Psihološki mehanizmi in vpliv dizajna programa na učinkovitost kampanj

Učinkovitost promocijskih kampanj je odvisna od razumevanja treh sočasno delujočih psiholoških mehanizmov, in sicer statusa, navade in odnosa (Henderson, Beck & Palmatier, 2011). Kampanja, ki temelji na enem mehanizmu (npr. statusu), lahko pri enem segmentu spodbudi angažiranje, pri drugem pa povzroči negativne učinke (občutek nepravičnosti). Dorotic, Bijmolt in Verhoef (2011) izpostavljata mehanizma "pritisk točk" (kratkoročno pospeševanje nakupov pred nagrado) in "nagrajeno vedenje" (dolgoročna sprememba navad). Liu (2007) ugotavlja, da se največja sprememba vedenja zgodi v prvih treh mesecih po vključitvi, kar pomeni, da so začetne promocijske kampanje ključne za vzpostavitev novih nakupnih navad. Verhoef (2003) nadalje dokazuje, da neposredna pošta vpliva na rast deleža stranke, ne pa na zadrževanje, saj orodja, učinkovita za en cilj, niso nujno primerna za drugega.

3. Ključni dejavniki za oceno učinkovitosti promocijskih kampanj

Pri analizi učinkovitosti kampanj je treba upoštevati več kritičnih dejavnikov. Prvič, samoizbira, kjer so stranke, ki se vključijo v program, pogosto že bolj zveste, zato primerjava med člani in nečlani precenjuje učinke; nujna je longitudinalna analiza iste skupine pred in po kampanji (Dorotic, Bijmolt & Verhoef, 2011; Verhoef, 2003). Drugič, konkurenčna nasičenost zmanjšuje učinkovitost, saj morajo kampanje iskati edinstvene vrednostne predloge, kot so ne-denarne koristi (prepoznava, ekskluzivni dogodki), ki jih konkurenca težko posnema (Mimouni-Chaabane & Volle, 2009). Tretjič je časovni okvir, ker kratkoročni učinki ne odražajo dolgoročne učinkovitosti, saj se trajne spremembe pri lahkah in zmernih kupcih pokažejo šele po več mesecih (Liu, 2007; Henderson, Beck & Palmatier, 2011). Nazadnje, preteklo vedenje pojasni večino variance (okoli 90 %), zato je treba realno oceniti pričakovane učinke, kjer je največji potencial za rast v segmentih lahkah in zmernih kupcev, ne v težkih, ki so že dosegli svoj maksimum (Verhoef, 2003).

Učinkovitost 2018 promocije

```
## -----
## 4. UČINKOVITOST 2018 PROMOCIJE (primerjava skupin)
## -----
# Opisna statistika po skupinah
```

```

df %>%
  group_by(`Enrollment Type`) %>%
  summarise(
    n = n(),
    povp_flights = mean(total_flights_sum, na.rm = TRUE),
    povp_distance = mean(total_distance, na.rm = TRUE),
    povp_CLV = mean(CLV, na.rm = TRUE),
    povp_accumulated = mean(points_accumulated, na.rm = TRUE),
    povp_redeemed = mean(points_redeemed, na.rm = TRUE),
    povp_redemption_rate = mean(redemption_rate, na.rm = TRUE),
    povp_dollar_redeemed = mean(dollar_cost_redeemed, na.rm = TRUE),
    churn_rate = mean(churned, na.rm = TRUE)
  )

## # A tibble: 2 x 10
##   `Enrollment Type`      n povp_flights povp_distance povp_CLV povp_accumulated
##   <chr>                <int>      <dbl>      <dbl>      <dbl>      <dbl>
## 1 2018 Promotion         971        45.8       68827.    8047.    103240.
## 2 Standard            15766        29.0       43437.    7985.    43437.
## # i 4 more variables: povp_redeemed <dbl>, povp_redemption_rate <dbl>,
## #   povp_dollar_redeemed <dbl>, churn_rate <dbl>

# Statistični test: CLV med Standard in 2018 Promotion (Wilcoxon, ker CLV ni nujno normalno porazdeljen)
wilcox.test(CLV ~ `Enrollment Type`, data = df)

##
## Wilcoxon rank sum test with continuity correction
##
## data: CLV by Enrollment Type
## W = 7683302, p-value = 0.8432
## alternative hypothesis: true location shift is not equal to 0

# t-test za primerjavo povprečnega števila poletov
t.test(total_flights_sum ~ `Enrollment Type`, data = df)

##
## Welch Two Sample t-test
##
## data: total_flights_sum by Enrollment Type
## t = 24.987, df = 1042.6, p-value < 0.00000000000000022
## alternative hypothesis: true difference in means between group 2018 Promotion and group Standard is not equal to 0
## 95 percent confidence interval:
## 15.54703 18.19698
## sample estimates:
## mean in group 2018 Promotion      mean in group Standard
## 45.84758                        28.97558

# Chi-kvadrat: ali je tip kartice povezan z enrollment type?
chisq.test(table(df$`Enrollment Type`, df$`Loyalty Card`))

##
## Pearson's Chi-squared test
##
## data: table(df$`Enrollment Type`, df$`Loyalty Card`)
## X-squared = 0.68438, df = 2, p-value = 0.7102

```

```

# Testi razlik med skupinama
wilcox.test(points_accumulated ~ `Enrollment Type`, data = df)

##
## Wilcoxon rank sum test with continuity correction
##
## data: points_accumulated by Enrollment Type
## W = 13176777, p-value < 0.00000000000000022
## alternative hypothesis: true location shift is not equal to 0
wilcox.test(points_redeemed ~ `Enrollment Type`, data = df)

##
## Wilcoxon rank sum test with continuity correction
##
## data: points_redeemed by Enrollment Type
## W = 5434755, p-value < 0.00000000000000022
## alternative hypothesis: true location shift is not equal to 0
wilcox.test(redemption_rate ~ `Enrollment Type`, data = df)

##
## Wilcoxon rank sum test with continuity correction
##
## data: redemption_rate by Enrollment Type
## W = 4248464, p-value < 0.00000000000000022
## alternative hypothesis: true location shift is not equal to 0

```

Na prvi pogled nam opisna statistika pokaže, da je promocija iz leta 2018 privabila 971 novih članov, ki so v obstoju naročnine leteli v povprečju kar 45-krat, medtem ko so normalne stranke letele le 29-krat v povprečju. Zelo hitro je jasno, da je promocija pripeljala stranke, ki so bolj pogosti uporabniki letalskih družb, kot standardno pridobljeni kartičarji.

Testi za primerjavo skupin po načinu vpisa (standardno ali promocijsko) kažejo naslednje rezultate. Stranke, ki so se vključile preko promocije, so v opazovanjem obdobju v povprečju opravile skoraj 17 letov več od standardno vpisanih strank. Ta razlika je statistično visoko značilna, saj Welchov t-test vrne rezultate $t = 24.987$ in $p\text{-value} < 2.2e-16$. Povprečni vrednosti vidni v tabeli pa sta za promocijsko skupino 45.8 in za standardno skupino 28.9.

Po drugi strani pa se CLV (customer lifetime value) med skupinama praktično ne razlikuje, saj so rezultati Wilcoxonovega testa $W = 7683302$ in $p\text{-value} = 0.8432$. Promocija torej ni pritegnila strank z višjo dolgoročno vrednostjo, temveč zgolj bolj aktivne letalce.

Na nadaljnjih testih vidimo, da je zboranje in koriščenje točk visoko značilno med skupinama, vendar pa nam samo ta rezultat ne pove, katera skupina je bistveno boljša. Zato se obrnemo na tabelo s primerjavo, kjer opazimo, da medtem ko promocijski člani zberejo bistveno več točk zvestobe, so standardno včlanjeni člani tisti, ki jih več porabijo. Redemption rate je v povprečju pri standardnih članih 1.7%, medtem ko je pri promocijskih le 0.4%.

Zato je zanimivo, da je promocija privabila stranke, ki letijo veliko, se pa ne ozirajo dosti na koriščenje ugodnosti, ki jih program nudi. Potrebna bi bila nadaljna obravnava po plačilnem razredu in izobrazbi, vendar sklep je, da stranke, ki veliko letijo nimajo finančnih zadržkov in jim tako točke zvestobe niso pomemben del programa. Morda so jim bolj važne druge ugodnosti, ki jih program zvestobe nudi, vendar teh podatkov pa žal nimamo.

Tip kartice zvestobe (Star/Nova/Aurora) pa ni statistično povezan s tipom vpisa, saj je Chi test vrnil rezultate $X\text{-squared} = 0.68438$ in $p\text{-value} = 0.7102$. Promocija torej ni bila bolj privlačna za določen segment kartic.

Pomembna opomba je, da ker gre za opazovalne podatke, višja aktivnost promocijske skupine ne pomeni nujno, da je promocija vzročno povečala angažiranost. Enako verjeten scenarij je samoselekcija, in sicer da so se bolj pogosti letalci raje odločili za vključitev preko promocije. Za bolj zanesljiv vzročni zaključek bi bilo treba primerjati angažiranost istih strank pred in po vpisu.

Primerjaj v tabeli iz poglavja 4: pri Standard skupini je povp_distance = 43.437 in povp_accumulated = 43.437 — popolnoma identično. Pri 2018 Promotion skupini pa je povp_distance = 68.827, povp_accumulated = 103.240, kar je natanko 1,5-kratnik. To ni naključje — nakazuje, da imajo promocijske stranke 1,5× množitelj točk na prevoženi km, standardne pa 1×. To je pomembna ugotovitev za tvojo nalogo “učinkovitost promocije”: pomeni, da promocijska kampanja verjetno ni bila zgolj marketinška (privabi nove člane), ampak je vključevala tudi strukturno bonus stopnjo nabiranja točk kot del ponudbe. To delno pojasni, zakaj promocijski člani nabirajo tako veliko več točk — ne le zaradi več letov, temveč tudi zaradi ugodnejšega razmerja točk/km. Priporočam, da to eksplicitno preveriš in izpostaviš:

```
df %>%
  group_by(`Enrollment Type`) %>%
  summarise(tocke_na_km = sum(points_accumulated, na.rm = TRUE) / sum(total_distance, na.rm = TRUE))

## # A tibble: 2 x 2
##   `Enrollment Type` tocke_na_km
##   <chr>              <dbl>
## 1 2018 Promotion      1.5
## 2 Standard           1
```

To bi lepo dopolnilo tvoj odstavek o tem, zakaj promocijski člani “zberejo bistveno več točk, a jih manj unovčijo” — zdaj imaš razlago tudi za zakaj zbirajo toliko več, ne le hipotezo o vedenju.

Manjkajo: - pogled tudi po izobrazbi in prihodku.

Faktorji, ki vplivajo na engagement

```
## -----
## 5. FAKTORJI, KI VPLIVAJO NA ENGAGEMENT
## -----

# Korelacija numeričnih spremenljivk z engagementom
df %>%
  select(Salary, CLV, total_flights_sum, total_distance, redemption_rate) %>%
  cor(use = "pairwise.complete.obs")

##           Salary          CLV total_flights_sum total_distance
## Salary      1.000000000 -0.021016986    -0.001653776   -0.002261964
## CLV        -0.021016986  1.000000000    -0.006916046   -0.005992790
## total_flights_sum -0.001653776 -0.006916046    1.000000000    0.967839881
## total_distance  -0.002261964 -0.005992790    0.967839881    1.000000000
## redemption_rate  0.009981686 -0.006658419    0.015660545   -0.004235114
##           redemption_rate
## Salary      0.009981686
## CLV        -0.006658419
## total_flights_sum  0.015660545
## total_distance  -0.004235114
## redemption_rate  1.000000000


library(reshape2) # za melt(), ali uporabi tidyr::pivot_longer

##
## Attaching package: 'reshape2'
```

```
## The following object is masked from 'package:tidyr':
##
## smiths
cor_matrix <- df %>%
  select(Salary, CLV, total_flights_sum, total_distance, redemption_rate) %>%
  cor(use = "pairwise.complete.obs")

cor_long <- melt(cor_matrix)

ggplot(cor_long, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(value, 2)), color = "black", size = 4) +
  scale_fill_gradient2(low = "steelblue", mid = "white", high = "firebrick",
    midpoint = 0, limits = c(-1, 1), name = "r") +
  labs(title = "Korelacijska matrika: Salary, CLV in engagement metrike",
    x = NULL, y = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Na grafu korelacije vidimo, da ni absolutno nobene korelacije, ki bi pojasnila aktivnost.

```
# Linearni model: kaj napoveduje število poletov?
model <- lm(total_flights_sum ~ Salary + Education + `Marital Status` +
  Gender + `Loyalty Card` + is_promo_2018, data = df)
summary(model)
```

```
##
## Call:
```



```
## lm(formula = total_flights_sum ~ Salary + Education + `Marital Status` +
##     Gender + `Loyalty Card` + is_promo_2018, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -47.131 -11.438   3.879  11.925  58.121
##
## Coefficients:
##              Estimate Std. Error t value
## (Intercept)    27.842309870   0.670703444  41.512
## Salary          0.000004200   0.000006268   0.670
## EducationDoctor -0.216336591   0.911056343  -0.237
## EducationHigh School or Below 0.453265122   0.609818543   0.743
## EducationMaster  0.485052968   0.773201749   0.627
## `Marital Status`Married    0.377154059   0.399097535   0.945
## `Marital Status`Single    0.281474003   0.505460426   0.557
## GenderMale      0.186506474   0.292140790   0.638
## `Loyalty Card`Nova    0.168137710   0.403374806   0.417
## `Loyalty Card`Star    0.519243046   0.387278518   1.341
## is_promo_2018TRUE    16.937215090   0.629640551  26.900
##
##              Pr(>|t|)
## (Intercept)    <0.0000000000000002 ***
## Salary          0.503
## EducationDoctor  0.812
## EducationHigh School or Below 0.457
## EducationMaster  0.530
## `Marital Status`Married    0.345
## `Marital Status`Single    0.578
## GenderMale      0.523
## `Loyalty Card`Nova    0.677
## `Loyalty Card`Star    0.180
## is_promo_2018TRUE    <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 16.31 on 12467 degrees of freedom
## (4259 observations deleted due to missingness)
## Multiple R-squared:  0.05511, Adjusted R-squared:  0.05435
## F-statistic: 72.71 on 10 and 12467 DF, p-value: < 0.00000000000000022
```

Korelacijska matrika pokaže, da so povezave med Salary, CLV in metrikami angažiranosti (št. poletov, razdalja, redemption rate) praktično ničelne (vse $|r| < 0,03$) – plača in CLV torej sama po sebi ne napovedujeta, koliko stranka leti. Pričakovano je le zelo visoka korelacija med total_flights_sum in total_distance ($r = 0,97$), kar je logično, saj gre za dve meri istega pojava (več poletov = več prepotovanih km), zato ju v modelu ne smemo uporabljati skupaj kot neodvisni spremenljivki.


Linearni model (total_flights_sum ~ Salary + Education + Marital Status + Gender + Loyalty Card + is_promo_2018) potrjuje ta vtis: edini statistično značilen napovednik je is_promo_2018 (+17,1 poleta, $p < 0,001$). Vse demografske spremenljivke – plača, izobrazba, zakonski stan, spol in tip kartice – niso statistično značilne napovednice angažiranosti. Model kot celota pojasni le 5,7 % variance ($R^2 = 0,057$), kar je nizko in kaže, da glavni dejavniki angažiranosti niso zajeti v razpoložljivih demografskih spremenljivkah, temveč verjetno v vedenjskih ali časovnih dejavnikih (npr. namen potovanja, sezona, življenjski dogodki), ki jih v tem naboru podatkov nimamo.

Sklep: demografija (kdo je stranka) pojasnjuje presenetljivo malo o tem, kako pogosto stranka leti – edini

dejavnik z jasnim in močnim učinkom je pripadnost 2018 promocijski kohorti.

Vizualizacija

```
## -----  
## 6. VIZUALIZACIJE  
## -----  
  
# 6a. Distribucija CLV po enrollment tipu (boxplot - primerjava skupin, robusten na osamelce)  
ggplot(df, aes(x = `Enrollment Type`, y = CLV, fill = `Enrollment Type`)) +  
  geom_boxplot(outlier.alpha = 0.3) +  
  labs(title = "CLV glede na tip vpisa v program zvestobe",  
        y = "Customer Lifetime Value", x = NULL) +  
  theme_minimal() +  
  theme(legend.position = "none")
```




```
# 6b. Časovna vrsta: povprečno število poletov na mesec po letih (učinek promocije v času)  
Customer_Flight_Activity %>%  
  group_by(Year, Month) %>%  
  summarise(povp_flights = mean(`Total Flights`, na.rm = TRUE), .groups = "drop") %>%  
  mutate(date = make_date(Year, Month, 1)) %>%  
  ggplot(aes(x = date, y = povp_flights)) +  
    geom_line(color = "steelblue") +  
    geom_vline(xintercept = as.numeric(make_date(2018, 1, 1)),  
               linetype = "dashed", color = "red") +  
  labs(title = "Povprečno število poletov skozi čas",  
        subtitle = "Rdeča črta = začetek 2018 promocije",
```

```
x = NULL, y = "Povp. Total Flights") +  
theme_minimal()
```

```
## Warning in scale_x_date(): A <numeric> value was passed to a Date scale.  
## i The value was converted to a <Date> object.
```


Povpre.no .tevilo poletov skozi .as

Rde.a .rta = za.etek 2018 promocije




```
# 6c. Redemption rate po tipu kartice in enrollment tipu  
ggplot(df, aes(x = `Loyalty Card`, y = redemption_rate, fill = `Enrollment Type`)) +  
geom_boxplot() +  
labs(title = "Stopnja unovčitve točk po tipu kartice in vpisa",  
      y = "Redemption rate", x = "Loyalty Card") +  
theme_minimal()
```

```
## Warning: Removed 1 row containing non-finite outside the scale range  
## (`stat_boxplot()`).
```



```
# 6d. Churn rate po enrollment tipu (bar chart - deleži)
df %>%
  group_by(`Enrollment Type`) %>%
  summarise(churn_rate = mean(churned)) %>%
  ggplot(aes(x = `Enrollment Type`, y = churn_rate, fill = `Enrollment Type`)) +
  geom_col() +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Delež odpovedi članstva po tipu vpisa", y = "Churn rate", x = NULL) +
  theme_minimal() +
  theme(legend.position = "none")
```

Dele. odpovedi .lanstva po tipu vpisa



(Tristan) Identificirajte segmente strank z visoko vrednostjo in predlagajte možne ukrepe za optimizacijo

Cilj je, da identificiramo stranke v segmente in ugotovimo kateri so tisti z visoko vrednostjo. Ker bomo uporabili za odkrivanje skupin v podatkovnem okvirju algoritem *k najbližjih sosedov (k-means)* moramo nujno spremenljivko **Salary** modelirati, saj boodo sicer NA vrednosti izključene iz algoritma. Za imputacijo bomo zaradi visokega deleža manjkajočih vrednosti in odvisnosti mankajoče vrednosti od opazovane spremenljivke same (samo nekateri izmed tistih z izobrazbo *College* ima mankajoče vrednosti) je potrebno uporabiti kompleksnejši multivariatni imputacijski algoritem. V tem primeru se odločimo za *missRanger*, ki deluje na principu naključnih gozdov.

```
# dodamo indikator manjkajoče plače in odliva
Customer_Loyalty_History_Log <- Customer_Loyalty_History_Log %>%
  mutate(
    Salary_Missing = if_else(is.na(Salary), 1, 0),
    churned = if_else(is.na(`Cancellation Year`), 0, 1) # 1 = zapustil, 0 = aktiven
  )

# izključimo izvirna datuma, vključimo pa churned
impute_exclude <- c("Postal Code",
  "Enrollment Year", "Enrollment Month",
  "Cancellation Year", "Cancellation Month")

# pripravimo podatke za imputacijo - obdržimo Loyalty Number, Loyalty Card, churned, ...
impute_data <- Customer_Loyalty_History_Log %>%
  select(-any_of(impute_exclude)) %>% # pika je bila odveč - zdaj je prav
```

```

mutate(across(where(is.character), as.factor))

# odstranimo konstantne stolpce (npr. Country)
constant_cols <- sapply(impute_data, function(x) length(unique(x)) == 1)
impute_data <- impute_data[, !constant_cols, drop = FALSE]

# churned = faktor (missRanger bolje obravnava faktorje)
impute_data <- impute_data %>%
  mutate(churned = as.factor(churned))

# imputacija z missRanger
set.seed(42)
Customer_Loyalty_History_Imputed <- missRanger(
  impute_data,
  verbose = 0, # a izpiše narejene procenke
  num.trees = 1000,
  maxiter = 100
)

# sum(is.na(Customer_Loyalty_History_Imputed$Salary)) # mora biti 0

```

Zdaj uporabimo agregirane vrednosti in naredimo nov združen data frame. Kot smo videli prej je smiselno zaradi *k-means* algoritma logaritmirati agregirane vrednosti in jih skalirati (standardizirati).

```

loyalty_imputed <- Customer_Loyalty_History_Imputed %>%
  select(`Loyalty Number`, Salary, CLV, Education, `Marital Status`,
    Gender, `Loyalty Card`, `Enrollment Type`, Salary_Missing, churned)

# log
activity_log <- Customer_Activity %>%
  mutate(
    log_total_flights = log1p(total_flights_sum),
    log_total_distance = log1p(total_distance),
    log_points_accum = log1p(points_accumulated),
    log_points_redeemed = log1p(points_redeemed),
    log_dollar_redeemed = log1p(dollar_cost_redeemed),
    log_avg_flights = log1p(avg_flights_per_month)
  ) %>%
  select(`Loyalty Number`, starts_with("log_"), active_months, redemption_rate)

# združeno za analizo
final_df <- loyalty_imputed %>%
  left_join(activity_log, by = "Loyalty Number")

# preveri
kable(summary(final_df))

```

```
# sum(is.na(final_df$Salary))      # mora biti 0

set.seed(42)
# spremenljive za segmentacijo
clust_vars <- c("log_total_flights", "log_total_distance",
               "log_points_accum", "log_points_redeemed",
               "log_dollar_redeemed", "active_months",
               "redemption_rate", "Salary", "CLV")


# pripravimo podatke za k-means
train_kmeans <- final_df %>%
  select(all_of(clust_vars)) %>%
  drop_na()      # varnostno, če bi kje ostal NA

# skaliranje
train_kmeans_scaled <- scale(train_kmeans)

# elbow
wss <- sapply(2:6, function(k) {
  kmeans(train_kmeans_scaled, centers = k, nstart = 25)$tot.withinss
})

plot(2:6, wss, type = "b",
     xlab = "Število skupin k",
     ylab = "Within-cluster sum of squares",
```

```
main = "Elbow plot")
```



Pri odločitvi za števila skupin si pomagamo z grafom, kjer iščemo optimalno število skupin ("koleno"). Odločimo se za 3 skupine.


```
set.seed(42)
# izberemo k = 3
k_optimal <- 3
km_final <- kmeans(train_kmeans_scaled, centers = k_optimal, nstart = 25)

barve_skupin <- c("#E41A1C", "#377EB8", "#4DAF4A")


# viz
fviz_cluster(km_final, data = train_kmeans_scaled,
  geom = "point",
  ellipse.type = "convex",
  palette = barve_skupin,
  ggtheme = theme_minimal()) +
  labs(title = paste0("K-means segmentacija (k = ", k_optimal, ")")) +
  scale_color_manual(values = barve_skupin) # enotne barve
```

```
## Scale for colour is already present.
## Adding another scale for colour, which will replace the existing scale.
```


K-means segmentacija (k = 3)



```
# toplotna karta centrov (interpretacija skupin)
as.data.frame(km_final$centers) %>%
  mutate(skupina = factor(row_number())) %>%
  pivot_longer(-skupina, names_to = "spremenljivka", values_to = "vrednost") %>%
  ggplot(aes(x = spremenljivka, y = skupina, fill = vrednost)) +
  geom_tile() +
  scale_fill_gradient2(low = "steelblue", mid = "white", high = "firebrick",
    midpoint = 0) +
  labs(x = NULL, y = "Skupina", fill = "Standardizirana\nvrednost") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Če pogledamo skupine osnovane na standardiziranih vrednostih dobimo tri skupine.

Skupina 1 to povprečno aktivni uporabniki. Za njih je značilno: zelo malo unovčenih dolarjev in točk, podpovprečna razdalja, število letov približno povprečno.

Skupina 2 to so nadpovprečno aktivni uporabniki. Za njih je značilno: nekoliko nadpovprečno unovčevanje dolarjev in točk, ostala aktivnost blizu povprečja.

Skupina 3 so podpovprečno redki/priložnostni leteči potniki. Za njih je značilno: zelo malo unovčenih dolarjev in točk, zelo malo zbranih točk, letijo precej manj in imajo nizko stopnjo unovčevanja.

Spremenljivke active_months, CLV in Salary med skupinami ne kažejo velikih razlik, zato niso ključne za razlikovanje segmentov.

```
set.seed(42)
# spremenljivke za segmentacijo (iste kot prej) ---
clust_vars <- c("log_total_flights", "log_total_distance",
               "log_points_accum", "log_points_redeemed",
               "log_dollar_redeemed", "active_months",
               "redemption_rate", "Salary", "CLV")

# brez NA
complete_rows <- complete.cases(final_df[, clust_vars])
sum(complete_rows) # naj bo 16736 (ali manj)

## [1] 16736

# matrika k-means
train_kmeans <- final_df[complete_rows, clust_vars] # uporabi indekse
train_kmeans_scaled <- scale(train_kmeans)
```

```

# final DF
final_df$segment <- NA
final_df$segment[complete_rows] <- km_final$cluster

# so vsi
table(final_df$segment, useNA = "ifany") # mora biti 3 skupine + NA za tiste, ki so bili izpuščeni

##
##      1      2      3 <NA>
## 3671 11361 1704      1

# povzetek
final_df %>%
  filter(!is.na(segment)) %>%
  group_by(segment) %>%
  summarise(across(c(Salary, CLV, log_total_flights, redemption_rate),
                    list(mean = ~mean(.), sd = ~sd(.))))


## # A tibble: 3 x 9
##   segment Salary_mean Salary_sd CLV_mean CLV_sd log_total_flights_mean
##   <int>      <dbl>      <dbl>   <dbl> <dbl>              <dbl>
## 1     1         11.2      0.292    8.74  0.653              2.97
## 2     2         11.2      0.287    8.75  0.649              3.53
## 3     3         11.2      0.293    8.78  0.672              0
## # i 3 more variables: log_total_flights_sd <dbl>, redemption_rate_mean <dbl>,
## #   redemption_rate_sd <dbl>

profile_data <- as.data.frame(km_final$centers) %>%
  mutate(segment = factor(row_number())) %>%
  pivot_longer(-segment, names_to = "spremenljivka", values_to = "vrednost")

# porofilni črtni graf
ggplot(profile_data, aes(x = spremenljivka, y = vrednost,
                        color = segment, group = segment)) +
  geom_line(size = 1.2) +
  geom_point(size = 3) +
  scale_color_manual(values = barve_skupin) +
  labs(title = "Profili segmentov (standardizirani centroidi)",
       x = "Spremenljivka", y = "Standardizirana vrednost",
       color = "Segment") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

```




Poglejmo še drugačno vizualizacijo porazdelitev spremenljivk glede na skupino.

```
box_vars <- c("Salary", "CLV", "log_total_flights", "redemption_rate")

# long
box_data <- final_df %>%
  filter(!is.na(segment)) %>%
  select(segment, all_of(box_vars)) %>%
  pivot_longer(-segment, names_to = "spremenljivka", values_to = "vrednost")

# Boxploti
ggplot(box_data, aes(x = factor(segment), y = vrednost, fill = factor(segment))) +
  geom_boxplot(outlier.alpha = 0.3) +
  facet_wrap(~ spremenljivka, scales = "free_y") +
  scale_fill_manual(values = barve_skupin) +
  labs(title = "Porazdelitev ključnih spremenljivk po segmentih",
       x = "Segment", y = "Vrednost") +
  theme_minimal() +
  theme(legend.position = "none")
```

Porazdelitev ključnih spremenljivk po segmentih



Poglejmo še kako se skupine razlikujejo po Education, Marital Status, Gender, Loyalty Card, Enrollment Type, Province.

```
# analiza kategorijskih spremenljivk po segmentih
# počistimo
final_df <- final_df %>%
  select(-any_of(c("Province", "City")))

# dodaj Province in City
province_info <- Customer_Loyalty_History %>%
  select(`Loyalty Number`, Province)

city_info <- Customer_Loyalty_History %>%
  select(`Loyalty Number`, City) %>%
  mutate(City = fct_lump_n(City, n = 5, other_level = "Other"))

final_df <- final_df %>%
  left_join(province_info, by = "Loyalty Number") %>%
  left_join(city_info, by = "Loyalty Number")

# names(final_df)

# sedaj definiraj seg_data
seg_data <- final_df %>% filter(!is.na(segment))

# nadaljuj z analizo (cat_vars, itd.)
cat_vars <- c("Education", "Marital Status", "Gender",
              "Loyalty Card", "Enrollment Type", "Province", "City")
```

```

# deleži
get_seg_props <- function(var) {
  seg_data %>%
    group_by(segment, !!sym(var)) %>%
    summarise(n = n(), .groups = "drop") %>%
    group_by(segment) %>%
    mutate(prop = n / sum(n) * 100) %>%
    ungroup() %>%
    select(segment, category = !!sym(var), prop)
}

props_list <- lapply(cat_vars, get_seg_props)
names(props_list) <- cat_vars

# po skupinah
cat_long <- seg_data %>%
  select(segment, all_of(cat_vars)) %>%
  pivot_longer(-segment, names_to = "spremenljivka", values_to = "kategorija")

cat_props <- cat_long %>%
  group_by(segment, spremenljivka, kategorija) %>%
  summarise(n = n(), .groups = "drop") %>%
  group_by(segment, spremenljivka) %>%
  mutate(prop = n / sum(n) * 100) %>%
  ungroup()

# Hi-kvadrat s Cramer's V
chisq_results <- sapply(cat_vars, function(var) {
  tbl <- table(seg_data[[var]], seg_data$segment)
  test <- chisq.test(tbl)
  n <- sum(tbl)
  cramer_v <- sqrt(test$statistic / (n * (min(dim(tbl)) - 1)))
  c(statistic = round(test$statistic, 2),
    df = test$parameter,
    p_value = round(test$p.value, 4),
    cramer_v = round(cramer_v, 3))
})

t(chisq_results) %>%
  as.data.frame() %>%
  kable(caption = "Hi-kvadrat test in Cramer's V za razlike med segmenti")


```

Table 1: Hi-kvadrat test in Cramer's V za razlike med segmenti

	statistic.X-squared	df.df	p_value	cramer_v.X-squared
Education	8.79	8	0.3600	0.016
Marital Status	4.02	4	0.4027	0.011
Gender	1.71	2	0.4261	0.010
Loyalty Card	8.84	4	0.0652	0.016
Enrollment Type	270.81	2	0.0000	0.127
Province	25.44	20	0.1852	0.028
City	9.53	10	0.4826	0.017

```
# združeni grafi
plot_list <- list()
for (var in cat_vars) {
  p <- cat_props %>%
    filter(spremenljivka == var) %>%
    ggplot(aes(x = factor(segment), y = prop, fill = kategorija)) +
    geom_col(position = "fill") +
    scale_y_continuous(labels = scales::percent) +
    labs(title = paste("Delež kategorij za", var),
         x = "Segment", y = "Delež", fill = var) +
    theme_minimal() +
    theme(axis.text.x = element_text(angle = 0))
  plot_list[[var]] <- p
}

# združi v mrežo
combined <- wrap_plots(plot_list, ncol = 2)
print(combined)
```



Ni statistično značilnih razlik med skupinami v ostalih kategorijah, pri $\alpha = 0,05$.

Poglejmo še kakšen je prispevek posamezne skupine CLV in kakšen delež celotne populacije posamezne skupine predstavlja.

```
# filter
seg_summary <- final_df %>%
  filter(!is.na(segment)) %>%
```

```

group_by(segment) %>%
  summarise(
    n_customers = n(),
    pct_customers = n() / nrow(.) * 100,
    total_CLV = sum(CLV, na.rm = TRUE),
    pct_CLV = sum(CLV, na.rm = TRUE) / sum(final_df$CLV, na.rm = TRUE) * 100,
    avg_CLV = mean(CLV, na.rm = TRUE)
  ) %>%
  ungroup() %>%
  arrange(segment)

kable(seg_summary, digits = 2,
      caption = "Velikost posameznih skupin in njihov CLV",
      col.names = c("Skupina", "N", "% Customers", "Total CLV", "% of CLV", "Avg CLV"))

```

Table 2: Velikost posameznih skupin in njihov CLV

Skupina	N	% Customers	Total CLV	% of CLV	Avg CLV
1	3671	21.93	32077.85	21.91	8.74
2	11361	67.88	99357.82	67.87	8.75
3	1704	10.18	14954.81	10.22	8.78

Skupine imajo v povprečju na uporabnika skoraj enak prispevek CLV, zaradi velikosti pa je komulativen prispevek 2. skupine največji CLV (67.9%), sledi 1. skupina (21.9%), na zadnjem mestu pa je 3. skupina (10.2%).

(Patricija) Napovedovanje odliva strank oziroma odpovedi ter predlaganje možnih ukrepov za njihovo zadržanje

Definiranje churn

```

# Nova spremenljivka Churn - binarna

Customer_Loyalty_History <- Customer_Loyalty_History %>%
  mutate(
    Churn = if_else(is.na(`Cancellation Year`), 0, 1)
    # Churn = 1 → stranka je zapustila članstvo
    # Churn = 0 → članstva ni zapustila
  )

```

Dodali smo novo spremenljivko Churn, ki je binarna, toraj zavzema vrednosti 0 in 1. 1 pomeni da je stranka prekinila članstvo in 0 da članstva ni zapustila.

V nadaljevanju smo pogledali podatke in ugotovili, da je članstvo zapustilo 2067 oseb, kar predstavlja 12% vseh kartičarjev.

```

Customer_Loyalty_History %>%
  count(Churn) %>%
  mutate(
    '%' = round(n / sum(n) * 100)
  )

```

```
## # A tibble: 2 x 3
```



```
##   Churn      n    `%`
##   <dbl> <int> <dbl>
## 1     0 14670    88
## 2     1  2067   12
```

Numerične spremenljivke

```
Customer_Loyalty_History %>%
  group_by(Churn) %>%
  summarise(
    n = n(),
    `mean salary` = mean(Salary, na.rm = TRUE),
    `median salary` = median(Salary, na.rm = TRUE),
    `mean clv` = mean(CLV, na.rm = TRUE),
    `median clv` = median(CLV, na.rm = TRUE)
  )
```

```
## # A tibble: 2 x 6
##   Churn      n `mean salary` `median salary` `mean clv` `median clv`
##   <dbl> <int>         <dbl>         <dbl>         <dbl>         <dbl>
## 1     0 14670         79438.         73530         7969.         5776.
## 2     1  2067         79371.         73193         8132.         5793.
```

Če gledamo odliv strank po plači in CLV ne opazimo velikih odstopanj. Deluje podobno.

Kategorične spremenljivke

```
# Leto odhoda
Customer_Loyalty_History %>%
  group_by(`Cancellation Year`) %>%
  summarise(
    churned = n()
  )
```

```
## # A tibble: 7 x 2
##   `Cancellation Year` churned
##               <dbl>   <int>
## 1                2013     43
## 2                2014    181
## 3                2015    265
## 4                2016    427
## 5                2017    506
## 6                2018    645
## 7                 NA   14670
```

```
# Mesec odhoda
Customer_Loyalty_History %>%
  group_by(`Cancellation Month`) %>%
  summarise(
    churned = n()
  )
```

```
## # A tibble: 13 x 2
##   `Cancellation Month` churned
##               <dbl>   <int>
```

##	1	1	155
##	2	2	139
##	3	3	149
##	4	4	136
##	5	5	148
##	6	6	165
##	7	7	186
##	8	8	208
##	9	9	176
##	10	10	180
##	11	11	212
##	12	12	213
##	13	NA	14670

Primerjava z vpisom


```
#####
# LETO
#####

enrollment <- Customer_Loyalty_History %>%
  count(`Enrollment Year`) %>%
  rename(
    Year = `Enrollment Year`,
    Enrollment = n
  )

cancellation <- Customer_Loyalty_History %>%
  filter(!is.na(`Cancellation Year`)) %>%
  count(`Cancellation Year`) %>%
  rename(
    Year = `Cancellation Year`,
    Cancellation = n
  )

year_data <- full_join(enrollment, cancellation, by = "Year") %>%
  mutate(
    Enrollment = replace_na(Enrollment, 0),
    Cancellation = replace_na(Cancellation, 0)
  ) %>%
  pivot_longer(
    cols = c(Enrollment, Cancellation),
    names_to = "Type",
    values_to = "Number"
  )

ggplot(year_data, aes(x = factor(Year), y = Number, fill = Type)) +
  geom_col(position = "dodge") +
  labs(
    title = "Customer enrollment and cancellation by year",
    x = "Year",
    y = "Number of customers",
    fill = "Type"
  )
```



```
#####
# MESEC
#####

enrollment_month <- Customer_Loyalty_History %>%
  count(`Enrollment Month`) %>%
  rename(
    Month = `Enrollment Month`,
    Enrollment = n
  )

cancellation_month <- Customer_Loyalty_History %>%
  filter(!is.na(`Cancellation Month`)) %>%
  count(`Cancellation Month`) %>%
  rename(
    Month = `Cancellation Month`,
    Cancellation = n
  )

month_data <- full_join(enrollment_month, cancellation_month, by = "Month") %>%
  pivot_longer(
    cols = c(Enrollment, Cancellation),
    names_to = "Type",
    values_to = "Number"
  )
```

```
ggplot(month_data, aes(x = factor(Month), y = Number, fill = Type)) +
  geom_col(position = "dodge") +
  labs(
    title = "Customer enrollment and cancellation by month",
    x = "Month",
    y = "Number of customers",
    fill = "Type"
  )
)
```



Status kartičarja

```
Customer_Loyalty_History %>%
  group_by(`Loyalty Card`) %>%
  summarise(
    customers = n(),
    churned = sum(Churn),
    `churn rate` = mean(Churn) * 100
  )
```

```
## # A tibble: 3 x 4
##   `Loyalty Card` customers churned `churn rate`
##   <chr>          <int>    <dbl>      <dbl>
## 1 Aurora         3429     449        13.1
## 2 Nova           5671     717        12.6
## 3 Star           7637     901        11.8
```

Pri stopnjah kartičarjev opazimo, da jih je največ odšlo iz skupine Star kar je tudi pričakovano, saj jih je tam največ ima pa najnižji Churn rate. Najvišji Churn rate opazimo pri skupini Aurora.

Pri spremenljivki spol tudi ne opazimo velikih odstopanj.

```
Customer_Loyalty_History %>%  
  group_by(Gender) %>%  
  summarise(  
    customers = n(),  
    churned = sum(Churn),  
    `churn rate` = mean(Churn) * 100  
  )
```

```
## # A tibble: 2 x 4  
##   Gender customers churned `churn rate`  
##   <chr>      <int>   <dbl>      <dbl>  
## 1 Female      8410    1055        12.5  
## 2 Male       8327    1012        12.2
```